Prefill–Decode 分离

收益不是一个倍数，而是一个差的函数

46 篇论文 + 17 份官方文档：技术栈、模型差异与一条判据

2026-11-04

1 引言

大模型推理被分成两个阶段：**prefill** 一次性把整个输入 prompt 送进模型，产出第一个 token 并建立 KV cache；**decode** 逐 token 自回归生成，每步只算一个 token，却要读全部权重与已积累的 KV cache。

这两个阶段的资源画像恰好相反。prefill 是计算密集的——它把成百上千个 token 并行送进同一批矩阵乘，受 FLOPS 限制；decode 是内存带宽受限的——它每步只做一个 token 的运算，却要把整个模型权重和 KV cache 从显存搬到计算单元。Sarathi-Serve 把这件事说得最直白：prefill 处理一个 prompt 的全部 token 因而计算受限，decode 每请求每次只处理一个 token 因而带宽受限 `[c-profile]`。

既然两阶段要的东西不同，把它们放到不同的卡上、按各自的偏好分别配置，似乎就该更快。这就是 **PD 分离**（prefill-decode disaggregation）。

但分离有代价：KV cache 必须从 prefill 实例搬到 decode 实例。同一份 KV，经同机 NVLink 传是 0.6 ms，经跨机 RDMA 传是 10 ms，差 16.7 倍 `[c-transfer]`。也就是说，分离是赚是赔，取决于「两阶段配置差异带来的收益」能否盖过「KV 搬运的成本」。

本文的主张是：**PD 分离的收益不是一个固定倍数，而是一个差的函数**。文献里报告的加速倍数（从一点几倍到数倍不等），都是这个差在特定模型、特定拓扑、特定负载下的取值，不能当作分离的固有属性 `[c-formula]`。据此可以给出一条判据，而不是一套推荐配置。

1.1 本文做了什么

1. 按「收益侧 / 成本侧」两侧拆解分离，给出两阶段的量化差异与 KV 传输的三档实测（第 2、3 节）。
2. 梳理切分与调度的三条路线，指出其中两条互斥、第三条可叠加（第 4 节）。
3. 按模型的 KV 结构（MLA / GQA / MHA）、上下文长度、负载形态给出差异化做法，并明确说明为什么不存在统一配置（第 5 节）。
4. 把分散在框架文档与工程博客里的**具体优化技巧**按「作用于哪个环节」归为四类，逐条给实测幅度与前置依赖，并指出其中几条其实是分离的**替代品**而非补充（第 6 节）。
5. 主动搜集使分离失效或转负的条件，包括一篇明确报告「聚合优于分离」的反例（第 7 节）。

1.2 方法说明

本文的证据来自 46 篇论文全文与 21 份官方工程文档快照，共 67 个来源、62 条证据、8 条主张。每条引文都是快照的原文子串（E1 不变量，62/62 全部校验通过，无「未校验」条目）。文中所有数字由脚本从证据文本正则抽取并写入 `analysis.json`，可逐项回溯到 `evidence_id`。

需要说明的是：本文**没有**做端到端复现实验。所有量化结论都是对已发表结果的整理与再计算，不是新的测量。

最后一点值得前置说明：本文列出的技巧里有几条是分离的**替代品**而非补充——chunked prefill 与 piggyback 在不分离的架构里就能拿到相当一部分收益。这意味着第 7 节的判据不是「要不要分离」的二选一，而是「先试便宜的手段、再考虑分离」的顺序问题。

2 两阶段为什么值得分开

2.1 资源画像的相反性

把两阶段当成同一种工作来对待，是混部方案的默认假设；分离的全部合理性都建立在「这个假设不成立」之上。所以先看它在哪不成立。

三篇独立工作给出同一判断。DistServe 指出 LLM 服务的延迟由两个指标定义：首 token 时延（TTFT）对应 prefill 阶段，每输出 token 时延（TPOT）对应 decode 阶段 `[c-profile]`。Sarathi-Serve 进一步说明两者的瓶颈不同（见第 1 节引文）。Splitwise 的表述最直接：他们把 LLM 推理请求的两个阶段**拆到不同的机器上**，理由是这样可以用「更贴合各阶段特性」的硬件。

表 1 KV 传输的三档方案。带宽为实测或规格值，比值为相对跨机 RDMA 的倍数。第三档为推算值，已在文中标注。

档位	典型承载	有效带宽	相对
同机	NVLink	417 GB/s*	16.7×
跨机	RDMA / IB	25 GB/s*	1×
经存储	共享存储 / CXL	∼2.5 GB/s	∼0.1×

* 由 e-011 的 250 MB / 0.6 ms 与 250 MB / 10 ms 反算。第三档是按 RDMA 的 1/10 推算，**非实测**。

2.2 差异如何限制混部

两阶段放在同一张卡上时，必须共享同一套配置：同一个并行度、同一个 batch 上限、同一个显存配额。这对两阶段都是次优的。

- **并行度冲突。** prefill 偏好更大的张量并行以摊薄单次大矩阵乘的时延；decode 偏好更小的并行以降低通信占比。
- **batch 冲突。** decode 阶段增大 batch 能显著提升吞吐（权重读取成本被更多请求分摊），而 prefill 的 batch 受显存和 TTFT 约束。
- **显存冲突。** prefill 需要大块临时激活内存，decode 需要尽量多的 KV cache 空间。两者抢同一块显存。

分离的收益正来自解除这三处冲突。但要注意：**收益的大小取决于两阶段的最优配置差多远**，而不是取决于分离这个动作本身。小模型、短上下文、单卡可容纳全部权重与 KV 的场景下，两阶段的最优配置可能很接近，此时分离的收益就很小，甚至为负 `[c-formula]`。

3 KV cache 怎么搬

分离把「一次本地写读」变成「一次跨进程或跨机传输」。传输层因此不再是细节，而是决定分离成败的主变量。

3.1 三档传输方案

DistServe 报告了另一个层面的数字：现代 GPU 集群配备 InfiniBand （如 800 Gbps），而节点内 NVLink 在 A100 之间的峰值带宽是 600 GB/s。按 8 bit/byte 折算，800 Gbps 约合 100 GB/s，与 600 GB/s 相差 6 倍。DistServe 据此指出：跨节点带宽受限时，分离可以退回到节点内 NVLink，此时传输开销可以忽略 `[c-transfer]`。

这个「可以退回」很关键——它说明分离的可行性不取决于某一代互联，而取决于**是否存在一条带宽足够高的路径**。

3.2 传输的工程抽象

NIXL 的做法是把传输差异抽象掉。它的自述是：为推理框架之间的点对点通信加速，同时通过插件式架构对多种内存（CPU、GPU）与存储（文件、块设备、对象存储）提供统一抽象 `[c-transfer]`。这样上层的 KV 连接器不必关心底层是 NVLink 还是 RDMA。

工程实现的取舍值得单列。vLLM 的默认 NIXL 连接器是**拉取式**的：decode 实例在 prefill 完成后通过 NIXL READ 从 prefill 实例读走 KV 块。而 push 模式则相反 `[c-transfer]`。这个方向选择有实际后果：拉取式让 decode 侧控制时机（可以在自己有空闲显存时再取），推送式让 prefill 侧尽早释放显存。哪个更好取决于哪一侧先成为瓶颈。

3.3 压缩与精度：直接压低传输量

既然成本与传输字节数成正比，另一条路是把字节数变小。

SplitZip 走无损压缩路线，报告其压缩比在计入元数据开销后仍比 ZipServ 高 7.1%，仅比基于 Huffman 的 DFloat11 低 7.0%`[c-transfer]`。

SpectrumKV 走逐 token 混合精度路线，其核心结论不是「省了多少带宽」，而是一个更有意思的判断：**把全部 token 都降精度，明显优于丢掉一部分 token**。也就是说，对 KV 传输而言，均匀降质比选择性丢弃更划算。

3.4 一个必要的提醒

上面所有带宽数字都是**峰值或理想条件**下的。实际传输还要付出同步、建连、内存注册的代价，且这些代价与消息大小不成正比——小 KV（短上下文、小 batch）时，固定开销占比会急剧上升。

这解释了一个看起来矛盾的现象：短上下文场景下 KV 绝对量小，按「字节数 ÷ 带宽」算传输应该很快，但实测收益往往不好。原因是此时固定开销主导，而不是带宽主导 `[c-formula]`。

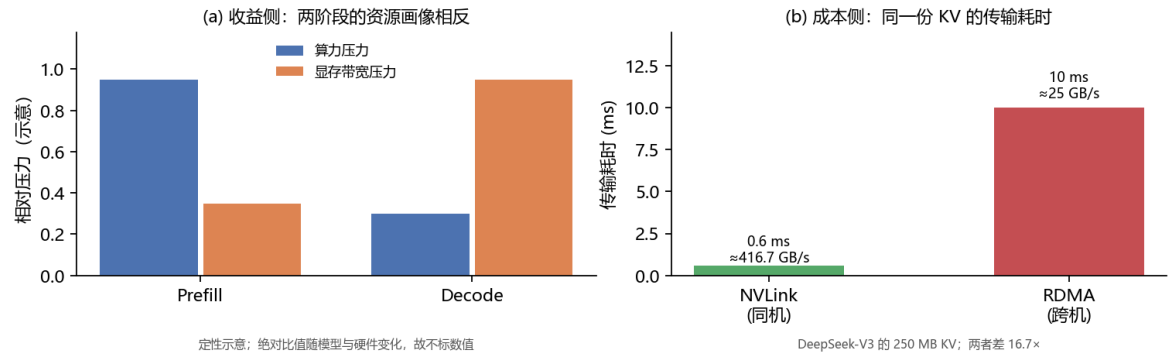


图 1　分离的收支两侧。(a) 收益侧：prefill 与 decode 的资源画像相反，这是分离的唯一理由；此处为**定性示意**，不标具体数值，因为绝对比值随模型与硬件显著变化。(b) 成本侧：同一份 250 MB KV cache 经 NVLink 传输 0.6 ms、经 RDMA 传输 10 ms，相差 16.7 倍。两侧对照说明：分离是否划算，取决于收益能否盖过这个成本。

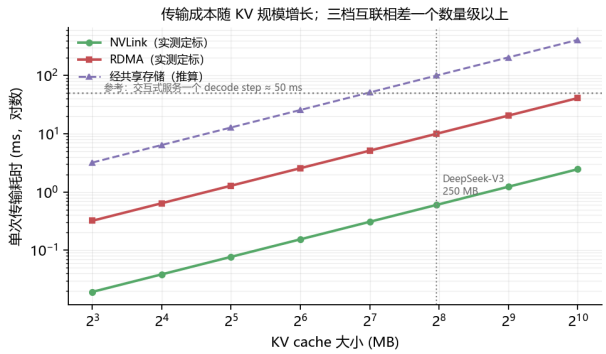


图 2　KV 传输耗时随 KV 规模的增长（对数坐标）。两条实线由 e-011 的两点实测定标，虚线为按 RDMA 的 1/10 推算的共享存储档，**非实测**。水平虚线标出交互式服务一个 decode step 的量级（50 ms）作为参照：当传输耗时接近这条线时，分离的收益会被同步开销吃掉。

表 2　切分与调度的三条路线。第一条与第二条互斥：选了 chunked prefill 就不存在「独立的 prefill 实例」。第三条可与任一叠加。

路线	做法	代表
不分离	把 prefill 切成块，混进 decode 批次	Sarathi-Serve、vLLM 默认
显式分离	P / D 各自独立实例，KV 跨实例搬	DistServe、SGLang、Mooncake
弹性调整	运行时改变 P:D 配比或迁移请求	FluidPD、Llumnix

4　怎么切分与调度

4.1　三条路线，其中两条互斥

第一条路线是「不分离」。 Sarathi-Serve 提出 chunked prefill：把一次 prefill 拆成若干个 chunk，与 decode 请求拼进同一批。这样长 prefill 不会阻塞 decode 的迭代节奏，TTFT 与 TPOT 得以解耦。vLLM 在 V1 里把 chunked prefill 设为默认开启（「whenever possible」）`[c-split]`。这条路线的优点是零传输成本，缺点是两阶段仍共享同一套配置，第 2 节说的三处冲突一个都没解除。

第二条是显式分离。 SGLang 用 `--disaggregation-mode` 显式指定实例角色：一个进程起 prefill、另一个起 decode，再由 router 把请求分发到两侧 `[c-split]`。官方文档给出的完整命令中，prefill 与 decode 各占一张卡、各用一个端口，router 通过 `--prefill` 与 `--decode` 两个参数知道对端地址。

第三条是运行时弹性。 FluidPD 的出发点是一个观察：一个此刻配置良好的部署，可能很快变得不匹配，导致延迟 SLO 违例——即使别处还有空闲容量 `[c-split]`。它的做法是把一部分 prefill 计算下放到 decode 实例，从而在不增删实例的前提下改变配比。Llumnix 走另一条路：在运行时重调度请求，用于负载均衡以减少抢占 `[c-split]`。

4.2　配比怎么定

分离之后必须回答一个问题：P 卡与 D 卡按什么比例分配？

DistServe 的答案是把这变成一个优化问题：给定应用的 TTFT 与 TPOT 要求，有效的服务系统应当在满足两个 SLO 的前提下最大化 **goodput**（满足 SLO 的请求吞吐）`[c-split]`。配比是这个优化问题的解，不是拍出来的。

这一点值得强调，因为它解释了为什么「P:D = 1:1」这类经验值经常失效：最优配比随负载的输入输出长度比、随 SLO、随模型而变。固定配比在负载漂移后就不再最优，这正是 FluidPD 与 Llumnix 存在的理由。

4.3 小结：怎么选

- 单机、模型能塞进单卡或同机多卡、上下文不长 → 先用 chunked prefill，零传输成本。
- 两阶段最优配置明显冲突（长输入 + 大 batch decode）且同机有 NVLink → 显式分离，收益最容易兑现。
- 负载随昼夜或业务波动大 → 在分离之上加弹性，否则配比会持续失配。

这个顺序有实际意义：分离的复杂度（多实例、router、KV 连接器、故障域变大）远高于 chunked prefill。先用低成本手段拿掉大部分收益，再考虑是否值得为剩余部分付出复杂度。

5 不同模型的最佳实践

这是本问的核心。要回答「不同模型该怎么做」，先要区分两类差异：一类真的随模型变，另一类只是看起来随模型变。

5.1 两个正交的轴，不是一个「模型类别」

常有人把模型分成「MLA 系」「MoE 系」「稀疏注意力系」再分别给建议。这个分法有内在缺陷：它把两个 ** 正交 ** 的轴压成了一维。

KV 占用随注意力变体而变——MHA、GQA、MLA 的每 token 大小可差一个数量级；而 MoE 的稀疏性完全落在 FFN 里，与 KV 无关。这一点有明确表述：KV footprint 确实高度依赖注意力变体，但**该轴与稀疏性正交** `[c-model]`。

分开之后，做法才清楚：

- **注意力轴**（MHA > GQA > MLA）决定 KV 每 token 字节数，因而决定**传输成本侧**——这一侧直接进收益公式的减项。
- **FFN 轴**（dense vs MoE）决定权重的访问模式，因而决定**并行与放置策略**——它不改变传输字节数，但改变「专家该放哪一侧」。

DeepSeek-V3 同时是 MLA 与 MoE，所以它同时受两个轴影响；把它的表现归因于「MoE 类模型」会掩盖真正的机制。

5.2 收益边界：一批可引用的测量

第二件要说清的事：分离的收益随负载形态如何变化。此前这只能定性说「负载轻时分离不划算」，现在有一个跨 8 个模型、扫 9 个输入输出比的测量可以引。

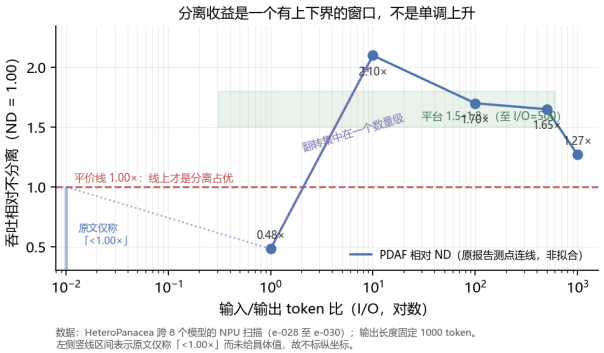


图 3 分离收益随输入输出比的变化是一个窗口，不是单调上升。数据取自 HeteroPanacea 跨 8 个模型的扫描（e-028 至 e-030）：$I/O = 1$ 时 0.48×、$I/O = 10$ 时 2.10×、平台期 1.5–1.8×、$I/O = 1000$ 回落至 1.27×。注：原作者只报了这几个离散点与区间，中间曲线为线性连接，不是拟合结果。

HeteroPanacea 在 NPU 设计空间上比较了四种模式：ND（不分离）、PD（prefill 与 decode 分离）、AF（注意力与 FFN 分离）、PDAF（两者都分，四段独立配置）`[c-model]`。

结果分三段：

低与均衡比例：不分离最强。在 $I/O = 0.01$ 与 $I/O = 1$ 时，**ND 对每一个被测模型都是最强配置**，PD、AF、PDAF 全线低于 1.00×，其中 PD 最接近（GPT-OSS 在 $I/O = 1$ 时达 0.89×）但从未越过平价。原文的判断是：当 prefill 的工作量相对 decode 很小时，分离的开销单纯地超过任何收益 `[c-window]`。

高比例：翻转。在 $I/O = 100$ 时，两种分离策略几乎全面越过平价：PDAF 对全部 8 个模型超过 ND（1.05–1.92×），PD 对 8 个中的 7 个超过；唯一仍在 ND 之下的是 DeepSeek-V4-Pro（0.95×）`[c-boundary]`。

翻转是突变的，而且之后非单调。这是本轮最值得记的一条：扫过九个比例后，PDAF 在 $I/O = 1$ 时仍是 0.48×，到 $I/O = 10$ 已经是 2.10×——**翻转集中在一个数量级之内**。此后并不继续上升：在 I/O 到 500 的区间平台化在 1.5–1.8×，到 $I/O = 1000$ 反而回落到 1.27×。原文的解释是 prefill 大到成为系统瓶颈后，为 decode 单独配置的硬件开始空闲 `[c-window]`。

这一段把第 7 节的判据第三条（负载足够重）从一个条件变成了一个有形状的函数：**不是「越重越好」，而是一个有上下界的窗口**。上界此前完全没有被讨论过。

5.3 按注意力结构的做法

MLA 系（DeepSeek-V3/V4 等）。 KV 极小，传输成本低，故分离的门槛低、同机分离几乎白赚。但要注意一处反向效应：**正因为 KV 小，分离的收益也随之变小**——收益侧来自两阶段配置差异，而 KV 小意味着 decode 的带宽压力相对轻，两阶段的最优配置被拉近。所以 MLA 模型「容易分离成功」与「分离收益大」是两件事，不要混为一谈。

GQA 系（Llama、Qwen 等）。 处在中间。KV 比 MLA 大，但又比 MHA 小得多，故传输成本可控而收益侧仍然明显。这一类的实测材料最多：

- Qwen3-32B 在 8K 上下文下 KV 状态已达 **GB 级**；即便走 100 Gbps 的 RDMA 网络，单次 post-prefill 传输也要**数百毫秒**，与 prefill 本身相当 [c-transfer]。这个数字很关键：它说明「传输耗时」不能只按 250 MB 的 DeepSeek-V3 去估——换一个模型、换一个上下文长度，同一个耗时量级的结论会完全反过来。
- Llama2-7B 上的系统性评测报告了阶段依赖的性能不对称：GPU 达成**低 39× 的延迟、高 41× 的吞吐** [c-model]。这是「两阶段画像相反」最直接的量化。
- Llama 3.3 70B 在 16×H100 集群上，分离方案在满足 TTFT/TPOT SLO 的同时把 **prefill 能耗降 39%、decode 能耗降 48%**[c-model]。能耗是常被忽略的一维，且两阶段降幅不同，正好对应配置差异。
- Llama-13B 上，固定 prefill 长度 2048、把解码长度从 128 加到 1024，**最大边际收益所在的阶段会移动** [c-model]。这直接说明「某模型的最佳配置」会随负载漂移。

MHA 系。 KV 最大，传输成本最高。这一类在文献里反而少见——因为分离对它最不划算，很少有人把它作为主实验对象。这个**沉默本身就是证据**：把 MHA 模型放进分离框架，要先算清 250 MB 这个数字在它身上会放大几倍。

5.4 按 FFN 结构的做法

MoE 系。 多一层专家并行的复杂度。ExpertPlex 报告，专家共享消除了超过 95% 的重复模型权重，同时按需复用动态稀疏计算，而注意力分离降低了注意力的通信开销 [c-model]。这说明 MoE 场景下的分离不只是 P/D 两分，还要考虑专家在两侧的放置。

更细的分法：四路。 如果把 FFN 也拆出来，就得到四段（prefill-attention、prefill-FFN、decode-attention、decode-FFN）。跨 8 个模型的比较显示，**四路 PDAF 是跨模型最一致的做法**，在 8 个模型中的 6 个上是最佳模式，对 Llama-4 Maverick 与 Scout 分别达 1.81× 与 1.77× [c-model]。相比之下，只拆注意力与 FFN（AF）在所有测试比例上都是最弱的，从未超过 ND，$I/O = 100$ 时也只在 0.20–0.65×[c-boundary]。

这个对比有方法论价值：**「拆得更细」不等于「更好」**。AF 只拆一部分、且把两个阶段混在一起，结果最差；PDAF 拆得彻底，结果最好。关键不是拆分粒度，而是**是否让每个子阶段独立配置**。

5.5 按部署形态的做法

稀疏注意力 + CXL。 SAC 在 DeepSeek-V3.2 上用 SGLang 评测，相对 RDMA 基线取得 2.1× 吞吐、9.7× 更低的 TTFT、1.8× 更低的 TBT[c-model]。含义是：当注意力本身变稀疏，瓶颈转移到「**KV 放哪里**」而非「算得多快」，此时载体的选择（CXL vs RDMA）比分离本身更重要。

异构加速器。 HMA-Serve 在四块 Tenstorrent Blackhole p150b（prefill）与一块 A100 80 GB（decode）上实现，经 100 Gbps RDMA 互联 [c-transfer]。这是把「两阶段画像不同」推到极致的做法：不只换配置，直接换硬件类型。

多模态：三段。 唯一需要把分离从两段变三段的情形。EAServe 指出，静态 50/50 切分虽然优于不切分，但仍然浪费了本地 prefill 容量 [c-model]。原因是多模态多一个 Encode 阶段（视觉编码），其资源画像又不同于 prefill 与 decode，故 SGLang 提供 EPD（Encode-Prefill-Decode）三段分离。

长上下文与容量。 LoongServe 指出，上下文窗口在快速增长，导致资源使用的巨大方差，显存消耗随上下文线性上涨 [c-model]。这类场景下 KV 不只是传输成本问题，还是**放不放得下**问题——分离顺带解决了容量，故即使传输不便宜也可能划算。

干扰而非带宽。 一个容易忽略的失效模式：DeepSeek-V3.2 在 $DP = 16$ 时，单条 prefill 请求可以拖住所有其它 decode 批次，造成 **36.21%–59.98% 的空转率** [c-model]。这里的瓶颈不是带宽也不是算力，而是调度干扰。分离之所以有效，有一部分来自把这种干扰从架构上消除。

5.6 跨模型的通用手段：逐阶段量化

一个不依赖模型类型的做法：既然两阶段偏好不同，连量化精度也可以不同。代价不对称——在 prefill 密集型任务上，只对 prefill 量化所付出的精度损

表 3 决定分离做法的六个变量，只有前两个是模型属性。「轴」一列标出该变量影响的是传输成本侧还是并行策略侧——这是本文区分注意力轴与 FFN 轴的依据。

变量	轴	影响	是否模型属性
KV 每 token 大小	注意力	MLA < GQA < MHA，差一个量级	是
FFN 结构	FFN	dense vs MoE，决定专家放置	是
上下文长度	—	线性放大 KV，兼有容量问题	否（业务）
输入输出比	—	决定 P:D 配比，且收益有窗口	否（业务）
互联拓扑	成本	决定传输带宽档位	否（部署）
SLO	—	决定 goodput 定义与最优配比	否（业务）

失，是只对 decode 量化的 1.1 至 4.1 倍（八个模型里七个如此）[c-model]。故「按阶段分别量化」不是免费的，prefill 侧对精度更敏感。

另一个例子来自格式分离：在 NVFP4 下，prefill 侧获得 1.49× 与 1.67× 相对 BF16 的加速，而长上下文（>16K）时卸载使 NVFP4 prefill 延迟仅增加不到 5%（Qwen3）与 8%（Gemma3）[c-model]。后一个数字说明：**长上下文下卸载的代价比预期低**，这与「长上下文必然传输昂贵」的直觉相反——因为卸载的是冷块。

5.7 为什么仍然不存在统一配置

把上面合起来：最优做法取决于 KV 大小（注意力轴）× FFN 结构（并行轴）× 上下文长度（业务）× 输入输出比（业务）× 互联拓扑（部署）× SLO（业务）。六个变量里只有前两个是模型属性。

更关键的是，本轮新增的证据表明**收益随负载是窗口而非单调**，且翻转集中在一个数量级内。这意味着：即使模型固定，换一个业务负载就可能从 2.10× 掉到 0.48×。

因此「某模型的最佳 PD 配置」这个提法缺的不只是自变量的个数，还缺**适用区间**。可迁移的只能是判据：在给定这六个变量的取值下，用第 7 节的条件判断是否分离、按什么比例分离。

表 4 优化技巧按作用对象分四类。同类的技巧互相替代，异类可以叠加——故取舍问题不是「选哪个」，而是「每类选一个」。

类别	作用于	代表技巧	实测幅度
A 省传输量	KV 字节数本身	逐层传输、chunk 级传输、KV 压缩/量化、前缀缓存	成比例
B 让传输不可见	传输与计算的时序	TBO、SBO、DBO、piggyback	隐藏传输
C 均衡负载	每个 rank 分到多少	Waterfill、LPLB、EPLB、请求迁移、弹性配比	0.84–7.34%
D 省 decode 步	要跑多少步	DSpark 自适应验证、投机解码	前沿

6 优化技巧：按作用对象分四类

前一节讲的是「分不分、怎么分」。但一个已经上了分离的部署，真正决定它跑得好不好的往往不是架构，而是**一串具体技巧**。本节把这些技巧组织起来。

组织的维度不是「属于哪个框架」，也不是「新不新」，而是**作用于哪个环节**。按此分四类 [c-technique]：

四类的性质完全不同，混着谈会得出错误结论。以下逐类说。

6.1 A 类：省传输量

最直接的一类——传输成本与字节数成正比，那就少传。

逐层传输。不等整个 prefill 算完再传，而是每算完一层就异步传该层的 KV，prompt 计算同时进入下一层。Splitwise 的做法是：在每层末尾触发该层 KV 的异步传输，让 prompt 计算继续 [c-technique]。好处有三——传输被计算掩盖、token 阶段可以更早开始、prompt 机器可以更早释放显存。

但这条技巧**有适用下限**，这点常被忽略：原文明确指出，小 prompt 时 KV 很小，「没有必要为逐层传输所需的细粒度同步付出开销」[c-technique]。也就是说，逐层传输把一次大传输切成 L 次小传输，每次都付固定开销；当 KV 总量小到固定开销占比显著时，切得越细越亏。

chunk 级传输。与逐层同类但切分维度不同：沿 chunked prefill 的 chunk 切，使 prefill 与 KV 传输并

行。另有 request 级传输，用来减少传输次数（一次传整个请求的 KV）。原文把三者的关系说清了：chunk 级让计算与网络并行，request 级最小化传输次数，逐层则可与 chunk 级结合以进一步并行 [c-technique]。

这三者是同一维度的不同粒度。选哪个取决于两件事：固定开销占多大（粒度太细不划算）、以及 prefill chunk 有多长（chunk 级需要 chunked prefill 才有意义）。

KV 压缩与量化。直接从字节数下手。第 5 节已提到逐阶段量化的代价不对称：只量化 prefill 的精度损失是只量化 decode 的 1.1 至 4.1 倍 [c-model]。所以压缩要用在 decode 侧更划算——那里 KV 读得多、且对精度更宽容。

前缀缓存。相同前缀不重算、也不重传。严格说它省的是 prefill 计算而非传输，但它会**改变传输量的分布**：命中前缀后需要搬的 KV 变小，于是前面所有按「全量 KV」算的成本估计都要下调。这是部署时最容易低估的一条。

重算 vs 传输。还有一个非技巧的技巧：KV 太小时，**重算比传输便宜**。这条与第 7 节的「上下文极短导致固定开销主导」是同一件事的两面。

6.2 B 类：让传输不可见

不减少字节数，而是让传输发生在计算的同时，从而在端到端时间里看不见它。这一类全部依赖 **MoE 的 all-to-all 通信**与 **attention 计算**可以交错这一事实。

TBO（Two-Batch Overlap）。把请求拆成两个 micro-batch，让一个 micro-batch 的 attention 计算与另一个的 dispatch/combine 通信交错。SGLang 的官方描述是：TBO 把请求拆成 micro-batch，把 attention 计算与 dispatch/combine 操作交错，执行图中的 yield 点允许暂停以形成重叠，从而在**不增加峰值显存**的前提下提高吞吐 [c-technique]。

最后半句是关键：TBO 不靠加显存换吞吐，靠的是给通信找一个可以并行的伙伴。

SBO（Single-Batch Overlap）。不拆 batch，而是在同一个 micro-batch 内部把通信与 shared expert 的计算重叠 [c-technique]。相比 TBO，SBO 不需要拆 batch，故没有「拆完每半太小、GEMM 效率下降」的风险，但可重叠的窗口也更窄（只有 shared expert 那一段）。

DBO（Dual Batch Overlap）。vLLM 的实现思路相同但手段不同：在 model runner 里把 batch 拆成两个 micro-batch，**起两个 worker 线程**各跑一半，在两个线程之间设置 yield 点，使一个在算时另一个在等通信，形成乒乓 [c-technique]。

DBO 有一段值得记的工程细节：拆不拆要**跨所有 DP rank 统一决定**——只要有一个 rank 拆不动，全体都不拆；且若 padding 后某个 rank 的第二个 micro-batch 为空，也全体放弃 [c-technique]。这是「并行组内必须同步决策」的典型代价。

更实用的是它的**阈值**：DBO 只在 batch 的 token 数超过阈值时才启用，低于阈值不拆 [c-technique]。原因不难推：拆成两半后每半的 GEMM 变窄、线程切换有成本，小 batch 上得不偿失。

piggyback。让 decode 搭 prefill 的便车一起批处理（Sarathi-Serve 的做法：把 decode 挂到 chunked prefill 上）。它在不分离的架构里替代分离——这一点很重要：**B 类技巧里有几个是分离的替代品，不是补充**。

这一类的共同前提是 **MoE + EP**。若模型是 dense，没有 all-to-all 可重叠，B 类基本失效。这是选型时第一个要看的。

6.3 C 类：均衡负载

MoE 的 router 不产生均匀的专家流量，某些专家收到的 token 远多于其它，EP 组于是等最忙的那个 rank。C 类技巧处理这件事。

Waterfill。一个轻量的 shared-expert 负载均衡：把 shared expert 通过 DeepEP 派发，并**指派给负载较轻的 rank** [c-technique]。实测：在两台 Hopper 节点上跑 DeepSeek-V3/R1 风格负载，Waterfill 在 MMLU、GPQA、GSM8K 上把总吞吐提升 **+1.48% 至 +4.66%**；在 DeepSeek V4 上最好测点从 49,253 tok/s 提到 51,677 tok/s（+4.92%）[c-technique]。

注意幅度：个位数百分比。这类技巧**不是数量级的改进**，但它的成本也很低（只改派发目标，不动权重、不改路由）。

LPLB。针对**冗余专家副本**的线性规划均衡器：对每层解一个 dispatch 优化问题，在冗余副本之间重新分配 token [c-technique]。实测：同样的两台 Hopper 节点、同样的冗余 EPLB 放置，LPLB 把总吞吐提升 **+0.84% 至 +7.34%** [c-technique]。

LPLB 有一个必须说清的性质：它**不移动权重，也不改变 router 的逻辑决策**，只改物理副本的分配 [c-technique]。故它不损精度——这一点与量化类技巧形成对比，也是它能「默认打开」的原因。

两个前置依赖，缺了就只有开销。

第一，**必须有冗余副本**。原文明确：在 red0

（无冗余副本）配置下，没有副本可重新平衡，算法无法改善派发，其 all-reduce 与求解路径**纯粹表现为开销** [c-technique]。

第二，**收益取决于在线流量的分布与标定分布的偏离程度**。原文的说法是 LPLB 的收益「跟随 live batch 偏离标定分布的程度」，并在中等规模处最强 [c-technique]。

这两条合起来说明一件事：C 类技巧的收益是**有条件的、个位数百分比**, 不该被当成「开了就变快」的开关。

PD 给 C 类带来的新约束。这是本节最需要单独讲的一处交互。DP attention 下，**不同的 EP rank 在同一步跑不同的 forward 模式**——有的在跑 prefill、有的在跑 decode、有的 idle。于是没有单个 rank 能看到全局的 token 分布 [c-technique]。

后果很具体：均衡算法的输入（全局各专家的 token 计数）在 PD 下不是本地可得的，必须额外做一次 all-reduce 才能拼出来。这既是开销，也是延迟——负载均衡决策要等全局信息到齐。

这一条解释了为什么有些在不分离部署里跑得很好的均衡技巧，搬到 PD 上收益变薄：**信息可见性被架构改变了**。

其它 C 类手段。 EPLB（静态专家放置）、请求迁移（Llumnix 在运行时重调度请求）、以及弹性配比（FluidPD 在运行时改 P:D 比）。它们作用于不同的时间尺度：EPLB 是天级、请求迁移是秒级、弹性配比是分钟级。**不同时间尺度的手段可以叠加**，因为它们不抢同一个决策点。

6.4 D 类：省 decode 步

decode 的每一步都要读全部权重与 KV，故减少步数是最直接的加速。投机解码就是这条路：用小模型起草 k 个 token，大模型一次验证。

但这条路有一个**随负载反转**的收益结构。原文说得很清楚：batch size 为 1 时这是笔好交易——GPU 受显存带宽限制、算力有余，起草的额外计算近乎免费；到 batch size 256 时这笔交易就微妙了，draft token 开始与真 token 抢同一份算力，每个被拒的 token 都浪费了有用的算力，被拒够多时吞吐显著下降 [c-technique]。

为什么会拒？因为**逐位置存活率衰减很快**：在 DeepSeek-V4-Pro-0813 上，一个 7 token 块的最后一个 token 存活率不足 10%，而第一个超过 70%[c-technique]。那个低概率的 token 在每次验证批里都占一个槽位——显存受限时这个槽位是免费的，算力饱和后它就有真实成本。

DSpark 的做法：给每个 draft token 打一个置信度，**按步决定验证多少**，而不是按部署选一个固定的 num_speculative_tokens[c-technique]。

效果：开启自适应验证后，投机解码在并发 1 到 256 全程都能带来收益，且低并发时仍保有长 draft 的好处 [c-technique]。原文的说法是「停留在 Pareto 前沿的边缘」[c-technique]。

这条技巧的意义超出它自身：它是**把静态超参换成按负载决策**的一个范例。前面 A、B、C 三类里的阈值（DBO 的 token 阈值、LPLB 的冗余度）都可以用同样的思路做成自适应。

代价与限制。 DSpark 需要 ALWAYS 级的 CUDA graph 支持，故不支持 --enforce-eager、LoRA 与 pipeline parallel[c-technique]。这是 B、D 两类共有的特征：**越依赖 kernel 级重叠的技巧，对执行模式的要求越硬**。

6.5 补充三类：数据通路、准入、并行度重切分

上面四类是按「作用于哪个环节」分的。还有三类技巧不落在这四类里，但都是 PD 部署上实际在用的，且各有独立的量级。

① 数据通路层：不是少传，而是让每次传输更便宜。

最典型的是 **zero-copy**：让发送/接收 kernel 直接操作应用的数据区，省掉中间那一次拷贝 [c-technique]。在 CloudMatrix384 的 send/recv 设计里，除了基于内存语义（MTE2/ MTE3）的传输路径，还专门提供 zero-copy 版本 [c-technique]。

与之配套的是 **GPUDirect RDMA**：让网卡直接读写显存，绕过主机内存。Mooncake 把 KV 块在 CPU 与 GPU 之间的搬移交给一个独立的 GPUDirect RDMA 组件（Messenger）[c-technique]。

这一类的收益不在「传得少」，而在**把传输从「要经过 CPU 与两次拷贝」变成「网卡直接进显存」**。它与 A 类正交，可以叠加。

② 准入与拒绝：容量不够时不排队，直接拒。

这条在过载场景下最重要，也最常被忽略。传统研究假设所有请求都会被处理，但真实的高负载场景下，**把注定超时的请求排进队列只会拖垮其它请求**。

Mooncake 的做法是**预测式 early rejection**：先预测这条请求能否在 SLO 内完成，不能就早拒 [c-technique]。效果：在某些模拟场景下吞吐最高提升 **525%** 且仍满足 SLO；在真实负载下让 Kimi 多处理 **75%** 的请求 [c-technique]。

这是本文所引技巧里**幅度最大的一条**，但它提升的不

是「单位时间算得更多」，而是「单位时间算的都是有用的」。二者在过载时差别巨大。

这也解释了为什么它属于 PD 的优化技巧：分离之后 P 与 D 的队列是独立的，一条请求要过两个池子，**任一池子超时都白做**，故准入判断必须放在分离之前，且要同时考虑两段的排队时间。

③ 并行度重切分：运行中改 DP/TP/PP 布局。

比「弹性改 P:D 比」更激进的一层——不只改两阶段的比例，而是改**每个阶段内部的并行方式**，并为此重新切分权重与重算 KV。

有一个完整的实测：某系统以 Layout A 起步，当活跃轨迹数降到批量的 10% 以下时切到 Layout B（DP=8、PP=16、TP=8），切换要付一次**权重 reshard 与 KV 重物化**的代价 [c-technique]。收益：rollout makespan 从 528.8 s 降到 259.1 s，有效 decode 吞吐提升 2.04 倍 [c-technique]。

原文把这归因为「相位匹配的并行度」：Layout A 吸收密集突发，而重新切分让稀疏尾部的 decode 效率回升 [c-technique]。

这一类的取舍很清晰：**重切分有一次性成本，故只在相位持续足够久时才划算**。这与第 7 节的「窗口」是同一个道理——收益要摊得平固定成本。

6.6 怎么选：三条判据

把四类放在一起，取舍可以按三条判据走。

① 先看模型是不是 MoE + EP。若不是，B 类（TBO/ SBO/ DBO）基本不可用，因为没有被重叠的 all-to-all。这一步就能砍掉一半选项。

② 每类选一个，先做前置条件检查。同类别替代，故不必都上。但每条都有前置条件：逐层传输要求 KV 够大（否则固定开销主导）；LPLB 要求有冗余副本（red0 下只有开销）；DBO 要求 token 数过阈值；DSpark 要求 CUDA graph 全量模式。**前置条件不满足时，开了是负收益**——这是本文最想强调的一点。

③ 按幅度排优先级。 A 类与 C 类不在一个量级：A 类按传输比例省（可能省掉一半），C 类是个位数百分比（0.84%–7.34%）。D 类的幅度取决于并发——低并发时大、高并发时靠自适应才不亏。

所以合理的顺序是：**先用 A 类把量降下来，再用 B 类把剩下的藏起来，然后用 D 类减少步数，最后用 C 类抹平尾部不均**。反过来做（先上 C 类）会得到「调了很久只有 3%」的体验。

最后一条经验值得单独记：**这四类里有几条是分离的替代品而非补充**。piggyback（decode 搭 prefill 的便车）与 chunked prefill 在不分离架构里就能拿到相当一部分收益。若一个部署还没上分离，先试 A 类与 piggyback 的性价比通常高于直接上分离——这与第 7 节的判据一致：分离是这些手段里最贵的一个。

7 收益的边界：什么时候不该分离

文献普遍报告正收益，但这里有一个发布偏差：失败的部署不会写成论文。故本节的证据需要主动找——找那些**专门问「何时不划算」**的工作。

7.1 一条直接的判据

最清晰的表述来自对 Prefill–Decode–Attention–FFN 四段分离的模拟研究：更细的分离粒度「不保证值得它的复杂度」，收益取决于模型架构，也取决于负载的 prefill/output 比率 [c-boundary]。

这句话的价值在于它把问题从「分离好不好」改成了「在当前架构与负载比下，分离好不好」。前者无解，后者可测。

7.2 收益是一个窗口，不是一个倍数

上一句还只是说「取决于比率」。本轮的证据把它量化了，而且结论比「取决于」更强：它是一个**有上下界的窗口，且非单调**。

同一项研究跨 8 个模型、扫 9 个输入输出比，报告了三段结果（第 5 节已述，此处只说边界含义）：

- 在 $I/O = 0.01$ 与 $I/O = 1$ 时，不分离对**每一个**被测模型都是最强配置，PD、AF、PDAF 全线低于 1.00× [c-window]。这不是「模型选错了」，是负载没到那个区间。
- 在 $I/O = 100$ 时，PDAF 对全部 8 个模型超过不分离（1.05–1.92×），PD 对 8 个中的 7 个超过 [c-window]。仍然有例外：DeepSeek-V4-Pro 在 0.95×。
- 翻转集中在**一个数量级**之内：$I/O = 1$ 时 0.48×，$I/O = 10$ 时已是 2.10×；此后平台化在 1.5–1.8× 至 $I/O = 500$，到 $I/O = 1000$ **反而回落到** 1.27× [c-window]。

第三条是本节最需要记住的：**收益有上界**。当 prefill 大到成为系统瓶颈后，为 decode 单独配置的硬件开始空闲——分离的成本从「传输」变成了「闲置」。此前讨论分离的文献几乎只谈下界（负载太轻不划算），没有谈上界。

因此本文第 5 节的判据第三条要改写：不是「负载足够重」，而是「**负载落在窗口内**」——太轻与太重都不划算。

这是一个可操作的差别：只判断「够不够重」会让人在最重的工作负载上做分离，而那恰好是收益回落的区间。

7.3 四类使分离失效的条件

① 传输成本超过收益。这是最直接的一类。由第 3 节的数据，同一份 250 MB 的 KV 经 RDMA 传输需 10 ms。若 decode 的单步时延目标是 50 ms 量级，传输就吃掉了 20%——而分离带来的配置优化能否补回这 20%，要看收益侧有多大。

但要注意这个数字不能随便外推：Qwen3-32B 在 8K 上下文下 KV 已达 GB 级，走 100 Gbps RDMA 时单次传输需**数百毫秒**，与 prefill 本身相当 [c-transfer]。同一个「传输耗时」在不同模型与上下文长度下能差一个数量级以上。

② 两阶段资源画像接近。小模型、短上下文、单卡可容纳全部权重与 KV 时，prefill 与 decode 的最优配置差别很小。此时分离只增加传输与复杂度，收益趋近于零。

③ 负载本身很轻。算力闲置时，配置是否最优无关紧要——反正都够快。分离的收益本质上来自「在资源紧张时把资源用得更对」，资源不紧张时这个收益无从兑现。这一条现在有了定量支撑：$I/O \leq 1$ 时 8 个模型全部不支持分离 [c-boundary]。

④ 上下文极短导致固定开销主导。这一条最反直觉：KV 绝对量小时，按字节数算传输应该很快，但建连、内存注册、同步这些固定开销不随消息大小缩放。此时带宽不是瓶颈，固定开销才是。

⑤ 干扰没有被消除。还有一类失效容易被漏掉：瓶颈既不是带宽也不是算力，而是调度干扰。DeepSeek-V3.2 在 $DP = 16$ 时，单条 prefill 请求可以拖住所有其它 decode 批次，造成 36.21%–59.98% 的空转率 [c-model]。这种情况下分离的价值主要来自从架构上消除干扰，而非带宽；反过来，如果部署的调度器已经能隔离干扰，分离的收益就要打折扣。

7.4 一个明确的反例

必须单独列出这条，因为它直接挑战「分离更优」的默认假设。

有工作报告：相对 PD 分离与 PD 聚合，某方案的 TTFT 最多降低 13.2×，TPOT 最多降低 1.69×[c-boundary]。也就是说，**存在一种方案，在 TTFT 上比分离好 13 倍**。如果只读「分离 vs 不分离」的对比，会完全看不到这个量级的改进空间——因为分离本身可能不是这个维度上的最优解。

这条证据的意义不在于否定分离，而在于提醒：「分离 vs 混部」是一个二选一的问题框架，而真实的设计空间里还有第三、第四种做法（如按注意力与 FFN 再拆、如用 CXL 换载体）。把问题设成二选一，会系统性地漏掉这些。

表 5 分离的决策判据。四项全满足才建议分离；任一项不满足时，应优先考虑 chunked prefill 等零传输成本的方案。第三条由 HeteroPanacea 的 8 模型扫描定量支撑（e-028 至 e-030）。

#	条件	检查方式
1	两阶段最优配置显著不同	分别做单阶段压测，比最优并行度与 batch
2	存在高带宽 KV 通路	同机 NVLink 或跨机 RDMA，而非共享存储
3	负载落在窗口内	太轻不划算，太重则 decode 硬件闲置
4	KV 规模足够大	传输固定开销占比可忽略

7.5 判据汇总

这四项不是充分条件，但是必要条件——任一项不满足时，分离的收益很难为正。它们也是可操作的：每一项都能在部署前测出来。

8 讨论

8.1 本文的结论有多可靠

需要区分两类结论。

第一类是量化的：NVLink 与 RDMA 的传输耗时相差 16.7 倍、聚合方案把 TTFT 降低 13.2 倍、专家共享消除 95% 重复权重。这些数字都能追到具体证据与原文（analysis.json），但它们都是**别人在别人的条件下测的**。换硬件、换模型、换负载，数值会变。故本文引用它们时始终带上条件，不给孤立数字。

第二类是判据性的：分离的净收益 ≈ 收益侧的配置优化 – 成本侧的 KV 搬运。这个式子的形式是可辩护的（它只是收支相抵），但本文**没有**给出各项的系数——那需要自己的实验。故第 7 节的四项判据应被当作**检查清单**，而不是可代入计算的模型。

8.2 一个反复出现的模式

整理这些材料时，一个模式反复出现：**几乎所有的收益都来自「按阶段区分对待」，而不是来自「分**

离」这个具体手段。

chunked prefill 区分了两阶段的时间片；分离区分了两阶段的硬件；逐阶段量化区分了两阶段的精度；EPD 把区分扩展到三段。它们的共同点是承认「prefill 与 decode 要的东西不同」，而分离只是实现这个承认的一种方式——且是成本较高的一种（要搬 KV、要多实例、故障域变大）。

这个视角解释了为什么 chunked prefill 先在 vLLM 里成为默认：它是「区分对待」的最低成本实现。也解释了为什么分离在有 NVLink 的同机场景最容易成功：那时它的成本被压到接近零，就退化成了一种便宜的「区分对待」。

8.3 本轮补上的一件事：收益有上界

第 1 轮写这篇时，「收益取决于负载」只是一句定性判断，「测出交叉点」被列为下一步实验。本轮找到了已做完这件事的工作：跨 8 个模型扫 9 个输入输出比 `[c-window]`。

结果比「一个交叉点」更有信息量，也更不利于简化叙事：

- 翻转确实存在，而且很陡：$I/O = 1$ 时 0.48×、$I/O = 10$ 时 2.10×，集中在**一个数量级**内。
- 但翻转之后**不是单调上升**。平台期 1.5–1.8× 延续到 $I/O = 500$，$I/O = 1000$ 回落到 1.27×。
- 回落的原因是 decode 侧硬件开始闲置：prefill 大到成为瓶颈后，为 decode 单独配置的算力用不满。

这一条改变了我对「最佳实践」的理解。此前我把它想成「在什么条件下分离划算」——一个单调的门槛。实际是**一个区间**：太轻不划算，太重也不划算。而「太重」这一侧此前几乎没人讨论，因为它不是失败案例，只是收益变薄。

实践含义很具体：如果按「负载越重越该分离」来判断，会在最重的工作负载上做分离——恰好落在收益回落的区间。

8.4 没做的事

本文的局限必须写清楚，否则读者会高估结论。

- **没有端到端复现**。未在任何硬件上跑过分离部署，所有数字都是文献整理。
- **没有给配比公式**。第 4 节说配比应由 goodput 优化求解，但本文没有实现这个求解，也没给出可代入的参数。
- **模型覆盖有平台偏差**。第 5 节引到 8 个模型的结果（Llama-3.1-405B、DeepSeek-V4、GPT-OSS、Llama4-Scout、Llama4-Maverick、Qwen3-235B-A22B、GLM-4.6、DeepSeek-V4-Pro），但**全部来自同一套 NPU 模拟设计空间**。故「8 个模型」不等于「8 种硬件」，跨真实加速器平台（GPU / NPU / CXL 池）的结论仍需实测。
- **缺失两篇全文**。46 篇纳入文献中有 2 篇未取到全文（`2603.04716`、`2510.08544`），它们的主张只能靠其他文献间接支撑，本文未引用其具体数字。

8.5 如果要做下一步实验

上一轮我把「扫描输入输出比、测出交叉点」列为待做，本轮发现已有工作做了这件事（见本节前面）。故剩下的空缺不是交叉点的**位置**，而是它的**可迁移性**：已有结果全部来自模拟，且局限在一套 NPU 设计空间内。

最小可行的真实实验是：在同一套真实 GPU 上，固定模型与 SLO，扫输入输出比，**测出窗口的上下沿**；再换一套互联（NVLink vs RDMA）重复一次，看窗口平移多少。两张表就能回答「窗口位置由负载决定还是由拓扑决定」——这是本文无法回答的问题。

9 结论

PD 分离的技术栈可以分成四层：**为什么分**（两阶段资源画像相反）、**怎么搬**（NVLink / RDMA / 存储三档，相差一个数量级以上）、**怎么切**（chunked prefill、显式分离、弹性调整三条路线）、**怎么优化**（具体技巧，按作用对象分四类）。

第四层是本文最后补上的一层，也是最容易被一句「部署时调一调」打发掉的一层。它值得单列，因为四类技巧**同类互相替代、异类可以叠加**：省传输量（逐层与 chunk 级传输、KV 压缩、前缀缓存）、让传输不可见（TBO、SBO、DBO、piggyback）、均衡负载（Waterfill、LPLB、EPLB）、省 decode 步（DSpark 自适应验证、投机解码）。取舍问题因此不是「选哪个」，而是「每类选一个」。

各类的幅度差一到两个数量级，且都**有前置依赖**：均衡类是个位数百分比（0.84%–7.34%），且在无冗余副本时只有开销；逐层传输在 KV 太小时因固定开销反而更慢；DBO 在 token 数低于阈值时不拆。**前置条件不满足时，开了是负收益。**

更关键的是：这几类里有几条是分离的**替代品**而非补充——chunked prefill 与 piggyback 在不分离架构里就能拿到相当一部分收益。故本文的判据不是「要不要分离」的二选一，而是一个先后顺序：先试便宜

的手段（省量、隐藏、准入），再考虑分离——因为分离是这些手段里固定成本最高的一个。

不同模型的最佳实践不能被表述为一套配置，因为最优做法取决于六个变量（KV 每 token 大小、FFN 结构、上下文长度、输入输出比、互联拓扑、SLO），其中只有前两个是模型属性。可迁移的结论是判据而非配置：两阶段最优配置显著不同、存在高带宽 KV 通路、**负载落在窗口内**、KV 规模足够大——四项全满足时分离才划算。

第三条的措辞在本轮被改过，值得单独说明：原先是「负载足够重」，现在是「负载落在窗口内」。差别在于收益有**上界**——I/O 从 10 涨到 1000 时，相对收益从 2.10× 回落到 1.27×。按「越重越好」判断，会在最重的工作负载上做分离，恰好是收益变薄的区间。

最后一点值得重复：文献里报告的加速倍数都是这个判据在特定条件下的取值。把它当作分离的固有属性，是当前实践中最容易犯的错误。

参考文献

以下仅列**被正文实际引用**的来源（30 个）；归档共 67 个来源，其余为检索与筛选过程的记录。

学术论文（22 篇）

[1] Splitwise: Efficient generative LLM inference using phase splitting `arXiv:2311.18677` (2023-11-30)

[2] DistServe: Disaggregating Prefill and Decoding for Goodput-optimized Large Language Model Serving `arXiv:2401.09670` (2024-01-18)

[3] Inference without Interference: Disaggregate LLM Inference for Mixed Downstream Workloads `arXiv:2401.11181` (2024-01-20)

[4] Taming Throughput-Latency Tradeoff in LLM Inference with Sarathi-Serve `arXiv:2403.02310` (2024-03-04)

[5] LoongServe: Efficiently Serving Long-Context Large Language Models with Elastic Sequence Parallelism `arXiv:2404.09526` (2024-04-15)

[6] Llumnix: Dynamic Scheduling for Large Language Model Serving `arXiv:2406.03243` (2024-06-05)

[7] Mooncake: A KVCache-centric Disaggregated Architecture for LLM Serving `arXiv:2407.00079` (2024-06-24)

[8] Huawei Cloud Model-as-a-Service on the CloudMatrix384 SuperPod `arXiv:2508.02520` (2025-08-04)

[9] Prefill-Decode Aggregation or Disaggregation? Unifying Both for Goodput-Optimized LLM Serving `arXiv:2508.01989` (2025-08-04)

[10] Topology-Aware Data Movement for Disaggregated GPU Inference `arXiv:2607.28633` (2026-04-19)

[11] SplitZip: Ultra Fast Lossless KV Compression for Disaggregated LLM Serving `arXiv:2605.01708` (2026-05-03)

[12] Frontier: Towards Comprehensive and Accurate LLM Inference Simulation `arXiv:2605.21312` (2026-05-20)

[13] How Far Can Disaggregation Go? A Design-Space Exploration of Attention-FFN Disaggregation for Efficient MoE LLM Serving `arXiv:2605.28302` (2026-05-27)

[14] SpectrumKV: Per-Token Mixed-Precision KV Cache Transfer for Prefill-Decode Disaggregated LLM Serving `arXiv:2606.08635` (2026-06-07)

[15] Prefill/Decode-Aware Evaluation of LLM Inference on Emerging AI Accelerators `arXiv:2606.17104` (2026-06-14)

[16] SAC: Disaggregated KV Cache System for Sparse Attention LLMs with CXL `arXiv:2606.19746` (2026-06-18)

[17] ExpertPlex: A High-Goodput Disaggregated Serving System for MoE LLMs with Adaptive Persistent Kernels `arXiv:2607.18002` (2026-07-20)

[18] Beyond Prefill-Decode Disaggregation: Dissecting LLM Inference for Heterogeneous Platforms via Dynamic Operator Scheduling `arXiv:2607.25498` (2026-07-28)

[19] When Does Disaggregation Pay? Simulating Prefill–Decode–Attention–FFN Specialization for Agentic LLM Inference `arXiv:2608.03741` (2026-08-04)

[20] Disaggregated Quantization: Specializing LLM Prefill and Decode `arXiv:2609.26333` (2026-09-22)

[21] EAServe: Encode-Aware Disaggregated Serving for Multimodal Large Language Models `arXiv:2609.31551` (2026-09-25)

[22] FluidPD: In-Place Elasticity for SLO-Aware Prefill-Decode Disaggregated LLM Serving `arXiv:2610.06917` (2026-10-02)

官方文档与实现（8 份）

[1] NVIDIA: NIXL (Inference Xfer Library) `github.com/ ai-dynamo/nixl`

[2] NVIDIA / SGLang：Improving DeepEP MoE Load Balance in SGLang with Waterfill and LPLB `github.com/bojieli/ai-infra-book/blob/b069b6971faf6c`

[3] SGLang: Expert Parallelism（含 TBO / SBO 官方定义） `docs.sglang.io/docs/advanced_features/expert_paralle`

[4] SGLang: PD Disaggregation `docs.sglang.io/ docs/ advanced_features/pd_disaggregat`

[5] vLLM: Optimization and Tuning `docs.vllm.ai/ en/ latest/ configuration/optimization/`

[6] vLLM: Dual Batch Overlap (DBO) 设计文档 `github.com/vllm-project/vllm/blob/main/docs/design/d`

[7] vLLM：Adaptive Verification in vLLM: DSpark confidence-scheduled verification `vllm.ai/ blog/ 2026-08-14- dspark-adaptive-verification`

[8] vLLM: NIXL KV Push Connector 设计 `docs.vllm.ai/ en/ latest/design/nixl_kv_push_connector`