RTX PRO 6000 Blackwell 的推理性能：一次以证据等级为准的综述

> 副标题：一个产品名下的三个 SKU、一张买到能力而非速度的卡，以及五个让测量失效的陷阱
>
> 数据快照：2026-10-29 | 来源：447 | 证据：3,002 | 主张：2,238
>
> 全文证据等级：所有数值最高为 测量级（measured），
> 无一条达到 复现级（reproduced） 或 发布级（released）。
>
> 注意 全文 SKU 约定：WS = Workstation Edition（600 W 主动散热）、
> MQ = Max-Q Workstation Edition（300 W）、SE = Server Edition（被动散热）。
> 凡来源未指明 SKU 的，标为「未指明」，不得当作三个 SKU 中的任何一个。

摘要

本文综述 NVIDIA RTX PRO 6000 Blackwell（GB202，96 GB GDDR7，sm_120a）在本地大模型推理上的性能表现，并与 RTX 5090、RTX 4090、RTX 6000 Ada 及数据中心加速器对照。我们不按「谁更快」组织材料，而按「这个数字能证明什么」组织。

核心发现有八。

第一，预填与解码是两条曲线，差 110 倍，故「这张卡多快」本身有歧义。
同一张卡、同一个模型、同一套 llama.cpp 单流测量：预填 4,757 tok/s，
解码 43.16 tok/s。预填瓶颈是算力，解码瓶颈是带宽，两者对硬件的要求几乎正交。
三条证据互相印证：同带宽的 RTX 5090 解码持平；功耗从 300 W 翻到 600 W
只让预填快约两成、解码几乎不动；互连（PCIe 对 NVLink）只在解码上拉开 66%。
故长提示短回答时它是很快的卡，短提示长回答时它是最弱的一维。
而首字延迟是第三个维度，与上面两个都不同步：同一对卡开 EP 让首字从
18,355 毫秒降到 673 毫秒（27 倍），吞吐只涨 2.3 倍、TPOT 几乎不变；
而 2 张 B200 靠 NVLink 把吞吐做到高 1.66 倍、TPOT 做到低 2.3 倍，
首字却是这张卡的 3.7 倍。

第二，这个产品名不是一个配置，而是三个。 同一名字下有 600 W 的 Workstation Edition、300 W 的 Max-Q、以及被动散热的 Server Edition。它们在同一模型同一命令下的解码吞吐差 12.9%-13.1%；在同一功耗点（300 W）上 Server 版比 WS 版快 38%。故「RTX PRO 6000 的 tok/s 是多少」这个问法本身需要先回答「哪个 SKU」。

第三，容量不构成约束时，这张卡与消费级旗舰几乎打平。 UL Procyon 四模型文本生成中，WS 版相对 RTX 5090 的 token 速率优势只有 1.5%-5.9%；而同一测试的总分差距达 8%-18%。同一个测试的两个输出给出两种图景。

第四，真正的差距出现在容量成为约束的边界上。 RTX 5090 无法加载 120B 模型，而这个系列以 163.15 tok/s 完成 GPT-OSS 120B；Llama 3.3 70B 上差距达 928%。但这个百分比不是「更快」，而是「对方跑不了」。

第五，与上代专业卡比，同一张卡有六个倍率，从 1.09 到 21.3，而它们都不假。
对 L40 Ada，多基准实测中位加速比 1.09 倍、胜率 78%、最差 0.85 倍、最好 1.67 倍；
而厂商宣称最高 5.6 倍（Llama 3 70B 单点口径）。0.85 与 5.6 是同一对显卡。
规格上 L2 缓存相对 RTX A6000 是 21.3 倍，而对推理的意义接近于零。
渲染则不同：SPECviewperf 15 中位 1.31 倍——因为渲染是算力受限，推理是带宽受限。

第六，与数据中心卡的对位分维度给出三种相反结论。 对 H100 NVL：
FP32 领先 2.1 倍、价格便宜 2.1 倍，而 FP64 落后 15 倍、带宽落后 2.2 倍。

而解码是带宽受限的，故单流解码在物理上不可能追上 H100——
H100 SXM5 的 3,352 GB/s 是这张卡 1,792 GB/s 的 1.87 倍。
成本上更尖锐：每芯片每小时 $0.68 是所列芯片最低（GB300 的 29%），
但每百万 token $0.19 是 GB300 的约 9.5 倍，因为并发约 10 对约 2,983。

第七，同一模型在预填与解码上的排名不同。 DeepSeek-V4/4.1-Flash 是本档案实测最多的模型线
（50 条主张、6 种硬件配置）。它在 300 W 档的解码上排第三（102.7 tok/s），在预填上排第四（6,341 tok/s）；
同一个模型、同一批数据，两个榜给出不同名次。而它在双卡 RTX PRO 6000 WS 上经五次改动把预填从
12,468 提到 13,811 tok/s（8k 上下文），并在单卡上跑满 1,048,576 上下文。

第八，96 GB 的收益必须换算成上下文预算才有意义。 按每 token 64 KiB 的 FP16 KV 成本，262K 上下文需 16 GiB，1M 需 64 GiB——后者才是单卡的真实上限，而它的约束不是 KV 而是「剩余 32 GiB 能否装下权重」。

---

1 引言：两个必须先回答的前置问题

任何关于这张卡的性能陈述，在给出数字之前都要先回答两个问题。

1.1 第一个问题：哪个 SKU?

「RTX PRO 6000 比 RTX 5090 快多少」这个问法有一个隐藏前提：「RTX PRO 6000」是一个确定的配置。它不是。

	Workstation (WS)	Max-Q (MQ)	Server (SE)
TDP	600 W	300 W	400-600 W 可配
显存带宽	1792 GB/s	1792 GB/s	1597 GB/s
标称 FP32	125 TFLOPS	110 TFLOPS	120 TFLOPS
散热	双风扇双流道	单风扇鼓风机	无风扇被动
外形	双槽	双槽	FHFL

而实测差距比规格表更大：

- 同一模型同一命令（gpt-oss-20b，tg128）：WS 286.91 tok/s，MQ 249.96 tok/s — 差 12.9% [c-sku-choice-changes-tok-s-by-13pct]
- 同一模型另一组（gpt-oss-120b）：WS 196.31，MQ 170.62 — 差 13.1%
- 同一功耗点 300 W：SE 比 WS 快 38%
- 自动化工具会把三者折叠成一个标识，于是「本型号需要驱动 575.57.08」这类声明会静默误伤 WS 与 MQ 版 [c-automation-collapses-three-skus-into-one-id]

> *** 判据（本文第一条）
>
> 当一个产品名对应多个 SKU 时，
> 「这个产品的性能是 X」这句话的误差棒等于 SKU 之间的最大差距——
> 而这个差距往往比被测的卡间差距还大。
>
> 故性能对比的最小单位不是「型号」，而是「型号 + SKU + 功耗上限」三元组。

本报告自身就违反过这条，而这件事现在是可被程序统计的：
claims.csv 新增了 sku 列（枚举 ws / mq / se / all / na / unspecified），
校验器会在每次通过的输出里报告 sku_unspecified。当前值是 244（共 2,238 条主张）。

而本文引用的 49 条主张里，有 17 条是 unspecified——即本文自己的表格里，
大约三分之一的引用无法定位到具体 SKU。这不是疏忽，而是上游来源没说：
Procyon 的原始记录只写「PRO 6000」，MLPerf 的配置表只写「RTX Pro 6000」。
把它们标成三个 SKU 中的任何一个，都会是编造。

1.1.2 SKU 判定的四条规则，以及它们各自的失败

把「是哪个 SKU」变成字段之后，剩下的问题是怎么判。这件事我做了四版，
每一版都被一个具体的误判推翻。记在这里，因为误判的类型比结论更有迁移价值。

第一版：用功耗当证据。 300 W 判 Max-Q、600 W 判 Workstation。
错在「整机功耗」「电源上限」这类与 SKU 无关的句子也含这些数字。
规则一：只用显式 SKU 名称，不用间接信号。

第二版：产品身份与 SKU 判定混在一起。 两者都看「陈述 + 全部证据原文」。
于是「RTX PRO 5000 72GB 版规格……」仅因其证据顺带提到 PRO 6000，
就被判成「提到该产品但未写明 SKU」。
规则二：产品身份只看陈述——一条主张讲的是哪个产品，由它自己的主语决定。

第三版：SKU 名称在全文任意位置都算。 证据里的「RTX PRO 4500 Workstation Edition」
让一条讲 PRO 6000 的主张被判成 ws——可那是 PRO 4500 的 Workstation 版。
规则三：SKU 名称必须紧邻产品名。一个 SKU 名称在自然语言里的作用域就是它旁边的那个型号。

第四版：单一窗口宽度。 60 字符太宽（「WS5090 比值」这种对照标注被当成 SKU），
42 字符又太窄（「RTX PRO 6000 WS 的 16-pin」里的 WS 紧邻却漏掉）。
规则四：完整 SKU 名用宽窗口，多义缩写用窄窗口。

最终实现见 scripts/classify_sku.py，并由 scripts/test_classify_sku.py 的
10 条回归用例钉住——每一条都对应上面的一次误判，或一次险些发生的误判。

> *** 判据
>
> 这四版的共同点是：每一版都在把一个更宽的文本范围当成「同一句话」。
> 先是把整份证据当成一句话，再把全文当成一句话。
> 而 SKU 的作用域比任何一层都小——它只覆盖它紧邻的那个型号名。
>
> 故「相邻」不是一个实现细节，它是语义本身。

1.1.3 一个必须排除的「第四个 SKU」

档案里有 16 条主张提到 RTX 6000D。它不是 PRO 6000 的第四个 SKU，
而是中国特供的独立产品：削减约 17% 计算单元（CUDA 24,064->19,968）、
显存 448-bit / 84GB、带宽降到 1.57 TB/s [c-6000d-spec][c-6000d-memory]。

把它的数字并进 PRO 6000 的任何一档，都会污染那一档的结论。
故只提 6000D 而不提 PRO 6000 的 10 条主张，sku 判为 na。

> ** 判据
>
> 「同一系列的不同型号」与「同一型号的不同配置」是两件事，
> 而它们的名字可能只差一个字母。前者要分开统计，后者要合并统计。

1.1.4 欠账清单

claim_id	claim_type	sku	陈述摘要
c-1m-feasible	measurement	unspecified	百万 token上下文在 RTX PRO 6000 上已可端到端跑通：DeepSeek V4 Flash 在 lla
c-gn-70b-capacity-domain	measurement	unspecified	LM Studio 的 Llama 3.3 70B Q4_K_S 测试中 PRO 6000 比 5090 提升 92

c-ix-paradox	derivation	unspecified	这里有一个必须说清的悖论：RTX PRO 6000 的 $/chip/hr 最低（0.68，是 GB30
c-ix-perdollar	measurement	unspecified	SemiAnalysis InferenceX 的每美元数据给出比本报告此前引用更完整的图景：Qwen 3.5 39
c-llamacpp-decode-parity	measurement	unspecified	在 llama.cpp 单流 decode 下，RTX PRO 6000 与 RTX 5090 接近持平——因为两者
c-llamacpp-prefill	measurement	unspecified	llama.cpp 上 RTX PRO 6000 的 prefill 吞吐：Qwen3.5-35B-A3B-Q8_0
c-omni3-vs-l40-median	derivation	unspecified	* RTX PRO 6000 相对 L40 Ada 的中位加速比为 1.09x、胜率 78%；p10 为 0.95、
c-slac-h100-vs-rtx	measurement	unspecified	* SLAC 的逐路径规格对比给出了一个比「谁更快」更实用的框架：FP32 上 RTX PRO 6000 约 125
c-slac-power-favors-h100	measurement	unspecified	注意 但机架密度下功耗倾向 H100：约 1.5 倍性能每瓦。即 RTX PRO 6000 在「每美元性能」上胜出，
c-sr-96gb-unique	measurement	unspecified	96 GB 的不可替代性在 120B 模型上得到直接验证：RTX 5090 无法加载或执行 120B 模型、甚至常处
c-sr-blender-narrow	measurement	unspecified	在 StorageReview 的受控并排测试中，PRO 6000 相对 RTX 5090 的 Blender 4.
c-sr-int8-saturates	measurement	unspecified	INT8 量化推理上 PRO 6000 与 RTX 5090 基本持平（79；064 对 79；272，5090 略
c-sr-renderer-split	derivation	unspecified	同一批评测中，PRO 6000 在 Blender（+6.3%）、LuxMark（+1.7%~5.0%）、Geekb
c-sr-token-vs-score	derivation	unspecified	Procyon 文本生成的 token 速率与总分给出了不同的图景：PRO 6000 相对 5090 的 token
c-sr-vray-loses	measurement	unspecified	V-Ray 6 上 RTX 5090 以 14；764 vpaths 领先 PRO 6000 的 12；128，领先
c-the-bonsai-readme-has-no-pro-6000-data	measurement	unspecified	注意注意注意 这份 24；840 字节的 README 里，「96 GB」「RTX PRO」「5090」「409
c-vgpu-l40s-56	measurement	unspecified	NVIDIA 宣称 RTX PRO 6000 相对 L40S 最高 5.6 倍加速（Llama 370B），分项为

表 4　本文引用中 SKU 未指明的主张（欠账清单）。

这 17 条不是「没查」，而是「查了、原始记录里就没有」。
把 unspecified 硬填成某个 SKU 会制造不存在的精度，
而把它隐藏起来则会让读者以为每个数字都能定位到具体产品。

1.2　第二个问题：这是性能结论还是容量结论？

同一个「快 N%」可以是两种完全不同的事。

类型	含义	例子
性能结论	两者都在跑同一任务，A 更快	Blender 上 WS 领先 5090 6.3%
容量结论	B 根本跑不了，只有 A 能跑	120B 模型上 5090 无法加载

后者写进「加速比」表格里，读者会以为这张卡快 10 倍；而实际情况是它在跑，另一张卡在 OOM。第 4 节专门处理这一类。

1.3 组织原则

每一节先声明它讨论的是哪一类比较、哪个 SKU，再给数字。凡出现「A 比 B 快 N%」，必须能回答：N% 的分母是什么、B 当时是否真的在跑同一个任务、A 是哪个 SKU。

2 硬件与软件边界

规格（WS 版，StorageReview 与 whitepaper 双向确认，两处独立记录一致）[c-sr-spec-confirm]：GB202，92,200M 晶体管，750 mm²，188 SM，24,064 CUDA，752 Tensor，188 RT，128 MB L2，512-bit，1.79 TB/s，600 W TDP，FP32 126.0 TFLOPS，FP64 1.968 TFLOPS（1:64）。

软件边界是本文最重要的限定条件之一。 Blackwell 在这个意义上不是一个平台，而是两个互不兼容的 CUDA 大版本：

产品	芯片	Compute Capability	目标架构
RTX PRO 6000（全部 SKU）	GB20x	12.0	sm_120a
B200	GB100	10.0	sm_100a
B300	GB300	10.3	sm_103a

而且 120-real 编译出的是 120a-real，不向前兼容。这意味着「为 Blackwell 编译」这句话至少有两种互斥的含义。

实测显存为 97,887 MiB（约 95.59 GiB），比标称 96 GB 少约 420 MiB 保留。注意这是 SE 上测得的，而三 SKU 的标注容量都是 96 GB。

> 注意 一条必须在引言处就说明的限制
>
> 官方不提供 Linux CUDA 二进制，因此所有 Linux 侧的吞吐数字，其构建配置不可追溯。「代码版本」这个变量在那批数据里是空的。

3 容量不构成约束时的推理性能

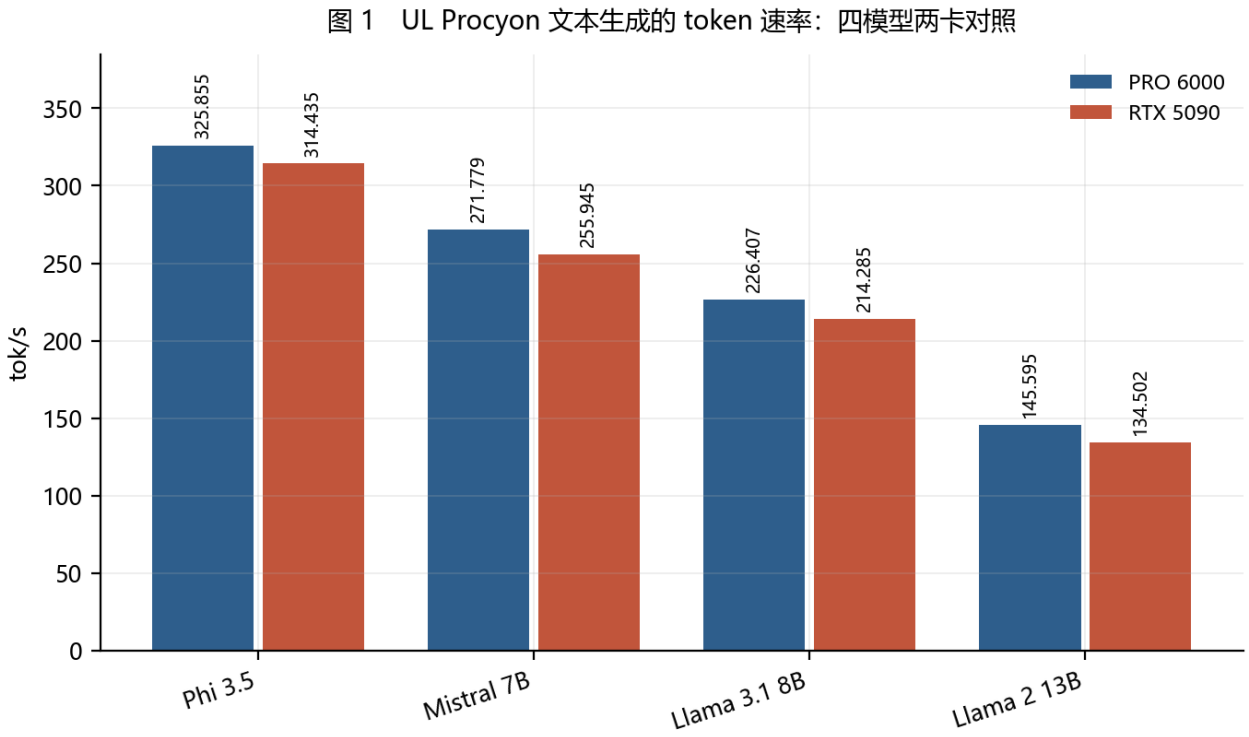


图 1　UL Procyon 文本生成的 token 速率：四模型两卡对照。

图 1 把四个模型的 token 速率并排放在一起，可以看到 PRO 6000 的领先幅度随模型变小而收窄。

同一批评测、同一软件栈下（WS 版对 RTX 5090），四模型的 token 速率：

模型	WS 版	RTX 5090	WS 领先
Phi 3.5	325.855	314.435	3.6%
Mistral 7B	271.779	255.945	6.2%
Llama 3.1 8B	226.407	214.285	5.7%
Llama 2 13B	145.595	134.502	8.2%

差距区间 1.5%-5.9%（评测方口径），量级与噪声同阶 [c-sr-token-vs-score]。

但同一测试的总分不是这个数。 Phi 总分 6,775 对 5,749（+17.8%）、Mistral 7,346 对 6,267（+17.2%）、Llama3 6,501 对 6,104（+6.5%）、Llama2 8,008 对 6,591（+21.5%）。

> *** 第一个方法论发现
>
> 同一个基准同时输出「token 速率」和「综合总分」，两者幅度差 3 倍。
> 原因是总分含首字延迟、加载时间与内存行为的加权，而 token 速率只测稳态解码。
> 故「Procyon 显示领先 18%」与「Procyon 显示领先 5%」都是真的，
> 而它们说的是两件不同的事。

另一条独立佐证：INT8 量化推理上两者基本持平——79,064 对 79,272，5090 反而高 0.3% [c-sr-int8-saturates]。原作者的解释是 INT8 负载对显存带宽与容量的依赖较低。

而 SKU 的影响在这里也被单独测到：MQ 版对 RTX 5090 在低到中并发（1-32）区间稳定慢 11%-13%，原因是 575 W 对 300 W 的功耗预算差异，而非核心数 [c-j8-maxq-vs-5090]。

*** 把这两条放在一起，得到一个反直觉的结论

同一个「RTX PRO 6000」：
600 W 的 WS 版比 5090 快 5%；300 W 的 MQ 版比 5090 慢 12%。
故「这张卡比 5090 快还是慢」的答案，取决于你买的是哪个 SKU，
而不取决于你测的是什么模型。

3.1 四档证据的对照

表 1 把本文四组关键数据的场景、数值与证据等级并列。这是全文唯一一张把「数字」与「它能证明什么」放在同一行的表。

档位	场景	关键数值	单位	证据等级	为何是这一级
容量不受约束	Mistral 7B 解码	271.779	tok/s	测量级	同批评测同软件栈，但只有单一实验室
容量不受约束	INT8 量化推理	79064	score	测量级	对位 5090 为 79272，差距 0.3% 在噪声内
容量成为约束	GPT-OSS 120B	163.15	tok/s	测量级	5090 无法加载该模型，故这是单选题而非对比
容量成为约束	Llama 3.3 70B 对 5090	928	百分比	诊断级	提升来自对方显存耗尽而非算力差

表 1　四个推理档位的对照（含证据等级）。

3.2 往上比：与 H100 / B200 / GB300 的对位

前一小节比的是消费级（5090、4090、6000 Ada）。真正决定这张卡定位的是往上一档：
它到底能不能替代 H100？本节的答案是分维度的，而每一维的答案都不同。

规格层：一赢一平三输

SLAC 给出了一份逐项规格对比，并注明「来自数据表而非在自家内核上实测」[c-slac-h100-vs-rtx]：

维度	RTX PRO 6000	H100 NVL	领先方
FP32	约 125 TFLOPS	约 60 TFLOPS	RTX 领先 2.1 倍
FP64	约 2.0 TFLOPS	约 30 TFLOPS	H100 领先 15 倍
显存带宽	1.79 TB/s	3.9 TB/s	H100 领先 2.2 倍
价格（2026-07）	约 $13,000	约 $28,000	RTX 便宜 2.1 倍

FP32 赢 2.1 倍、价格赢 2.1 倍，而 FP64 输 15 倍、带宽输 2.2 倍。

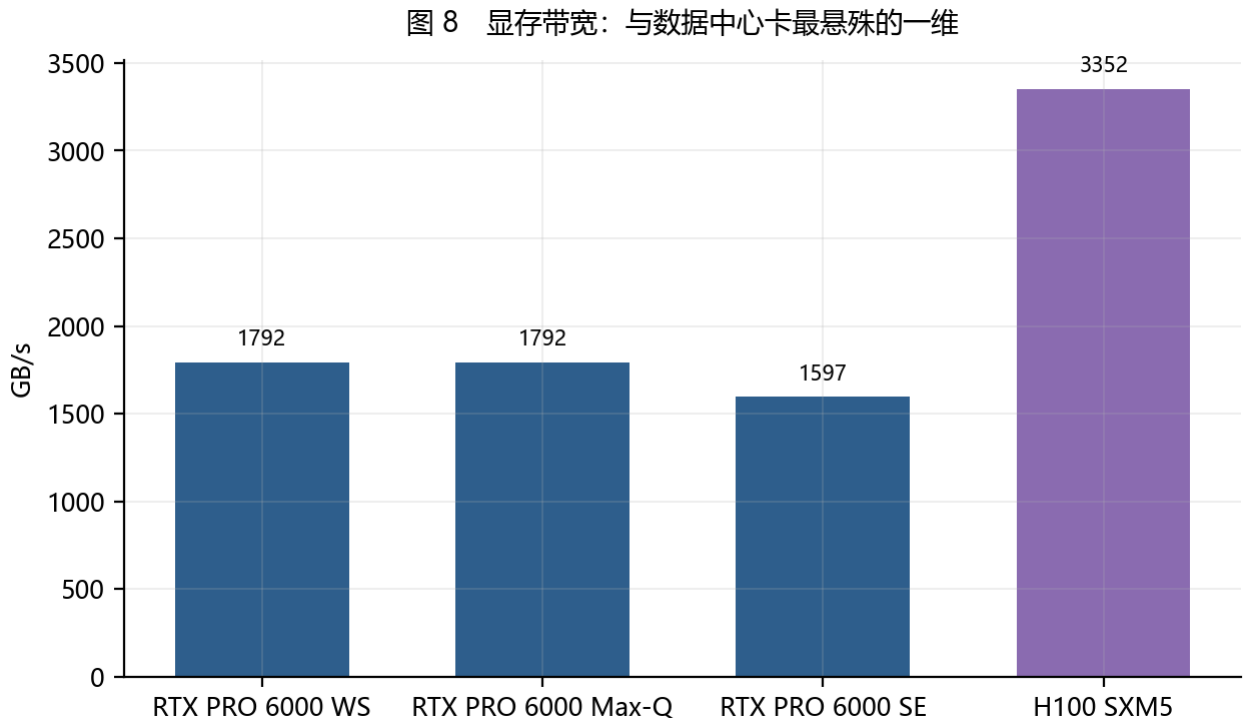


图 8　显存带宽：与数据中心卡最悬殊的一维。

图 8 只画了四个有确切数值的档位，把这张卡与数据中心卡的差距压缩成一个可以一眼比较的高度差。

带宽是本节最关键的一维，因为解码是带宽受限的：
H100 SXM5 的 3,352 GB/s 是这张卡 1,792 GB/s 的 1.87 倍 [c-hbm-bw-gap]，GH200 约 4.0 TB/s（2.2 倍）。
而 H100 NVL 在 SLAC 的对照里记为「约 3.9 TB/s」[c-slac-h100-vs-rtx]。
图 8 只画了有确切数值的四档；后两个在来源里是「约」值，故不画柱以避免伪造精度。

> *** 判据
>
> 故在单流解码这个最常被引用的场景里，
> 这张卡在物理上不可能追上 H100：因为解码每生成一个 token 都要读一遍权重，
> 而读的速度差 1.87 倍。
>
> 而它在 FP32 上赢的 2.1 倍，对这个场景完全无用。
>
> 这就是「跑分赢、推理输」的物理原因，不是软件问题。

互连层：PCIe 对 NVLink，差 66%

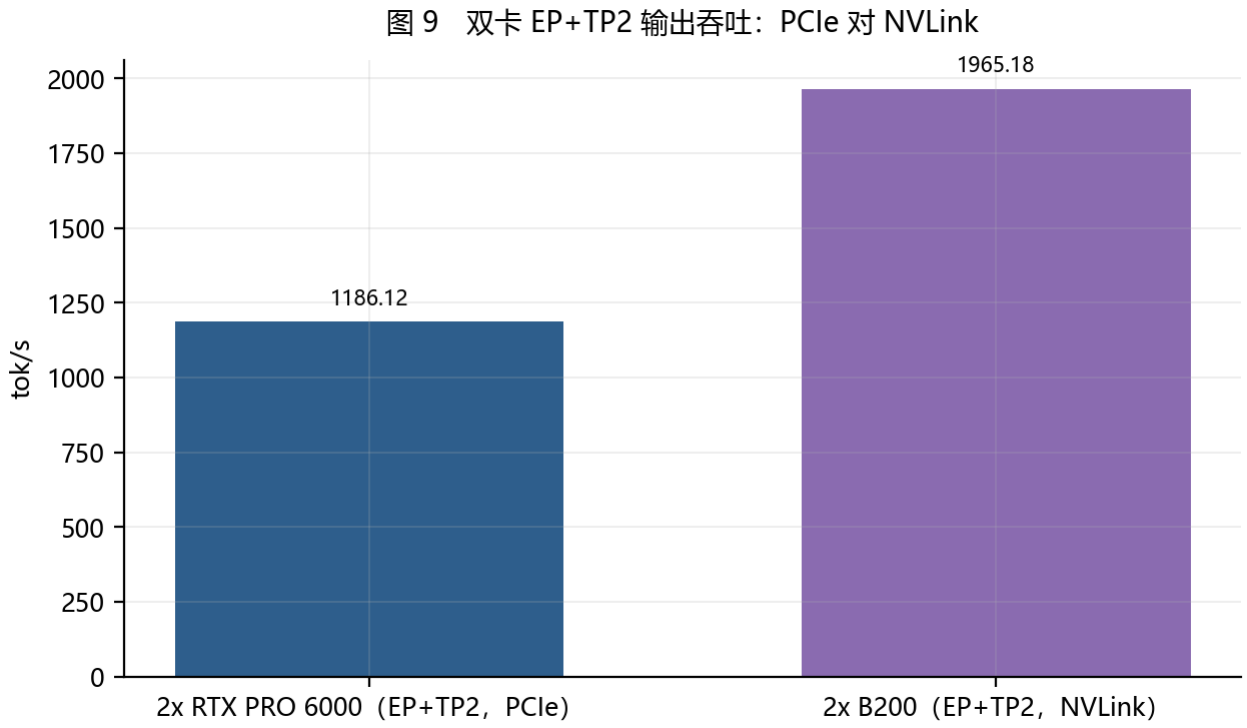


图 9　双卡 EP+TP2 输出吞吐：PCIe 对 NVLink。

图 9 的两组柱子共用同一套并行配置，故 66% 的差距只能归因于互连。

一条对照组数据把互连的代价单独量了出来 [c-ep-gap]：
同为双卡、同开 EP+TP2，
2x B200（NVLink）输出 1,965 tok/s，2x RTX PRO 6000（PCIe）为 1,186 tok/s；
TPOT 5.63 ms 对 12.82 ms（快 2.3 倍）。

> ** 判据
>
> 这是本文唯一一条「只换互连、不换算力」的对照，
> 故它测的是 PCIe 与 NVLink 的差，不是两张卡的差。
>
> 而它给出的量级（66% 吞吐、2.3 倍 TPOT）意味着：
> 任何多卡推理的对比，只要一侧有 NVLink 另一侧没有，
> 这个差就会混进「卡间性能差」里而无法分离：除非像这条一样把 EP+TP2 固定住。

成本层：买得起不等于用得起

这是三种相反结论里最尖锐的一种：按芯片成本排它最低，按 token 成本排它最高。

具体数字、并发差异与全部八个指标见 §9——那一章专门处理成本，
因为这里若展开，就会与那里重复同一组数。

> *** 判据
>
> 成本比的分子必须是「每单位产出」，而不是「每单位时间」。
> 这不是定价策略的差别，是分母选错的差别。

功耗层：两个指标指向不同的卡

还有一维必须单列，因为它与前几维的结论相反 [c-slac-power-favors-h100]：
在机架密度下，H100 约领先 1.5 倍性能每瓦。

> ** 判据
>
> 至此这张卡的定位在三个指标上是三种结论：
> 每美元性能赢（便宜 2.1 倍）、每瓦性能输（落后 1.5 倍）、
> 每 token 成本大输（差 9.5 倍）。
>
> 故「RTX PRO 6000 与 H100 谁更好」这个问题没有单一答案，
> 只有「在哪个约束下更好」。

3.3 往下比：与上代专业卡的对照

比消费级是「值不值」，比数据中心是「能不能替代」，而比上代是升级决策里最实际的一问：
我这台机器上的 RTX 6000 Ada 或 L40S，换不换？

本节的答案是：同一张卡对上代有六个倍率，从 1.09 到 21.3，而它们都不假。

对照对象	维度	上代数值	本代数值	倍率	口径
RTX 6000 Ada	显存容量	48 GB	96 GB	2.0	规格
RTX 6000 Ada	显存带宽	960 GB/s	1792 GB/s	1.87	规格
RTX 6000 Ada	L2 缓存	98304 KB	131072 KB	1.33	规格
RTX A6000	L2 缓存	6144 KB	131072 KB	21.3	规格
RTX 6000 Ada	SPECviewperf 15 几何均值	1.0	1.47	1.47	实测渲染
RTX 6000 Ada	SPECviewperf 15 中位数	1.0	1.31	1.31	实测渲染
L40 Ada	多基准中位吞吐	1.0	1.09	1.09	实测推理
L40 Ada	多基准吞吐 p90	1.0	1.28	1.28	实测推理
L40 Ada	厂商宣称 Llama 3 70B 加速	1.0	5.6	5.6	厂商声明
L40S	Parabricks Fastq2bam	1.0	1.5	1.5	厂商声明

表 6　与上代专业卡的对照（按口径分行）。

规格倍率最容易骗人

先看两个最悬殊的规格项。容量从 48 GB 到 96 GB（2.0 倍）、
带宽从 960 GB/s 到 1,792 GB/s（1.87 倍）[c-gen-gain]。

而 L2 缓存从 RTX 6000 Ada 的 98,304 KB 到 131,072 KB（1.33 倍），
若与更早的 RTX A6000 的 6,144 KB 相比则是 21.3 倍 [c-l2-cache]。

> *** 判据
>
> 21.3 倍这个数字是真的，但它对推理性能的意义接近于零。
> 因为 L2 缓存的收益取决于工作集能否装进去，
> 而不取决于「比三代前大多少倍」。
>
> 故同一个「代际提升」，选不同的基线可以差 20 倍。
> 说「提升 N 倍」而不说「相对谁」，等于没有信息。

实测：显存差 2 倍，吞吐只差 1.09 倍

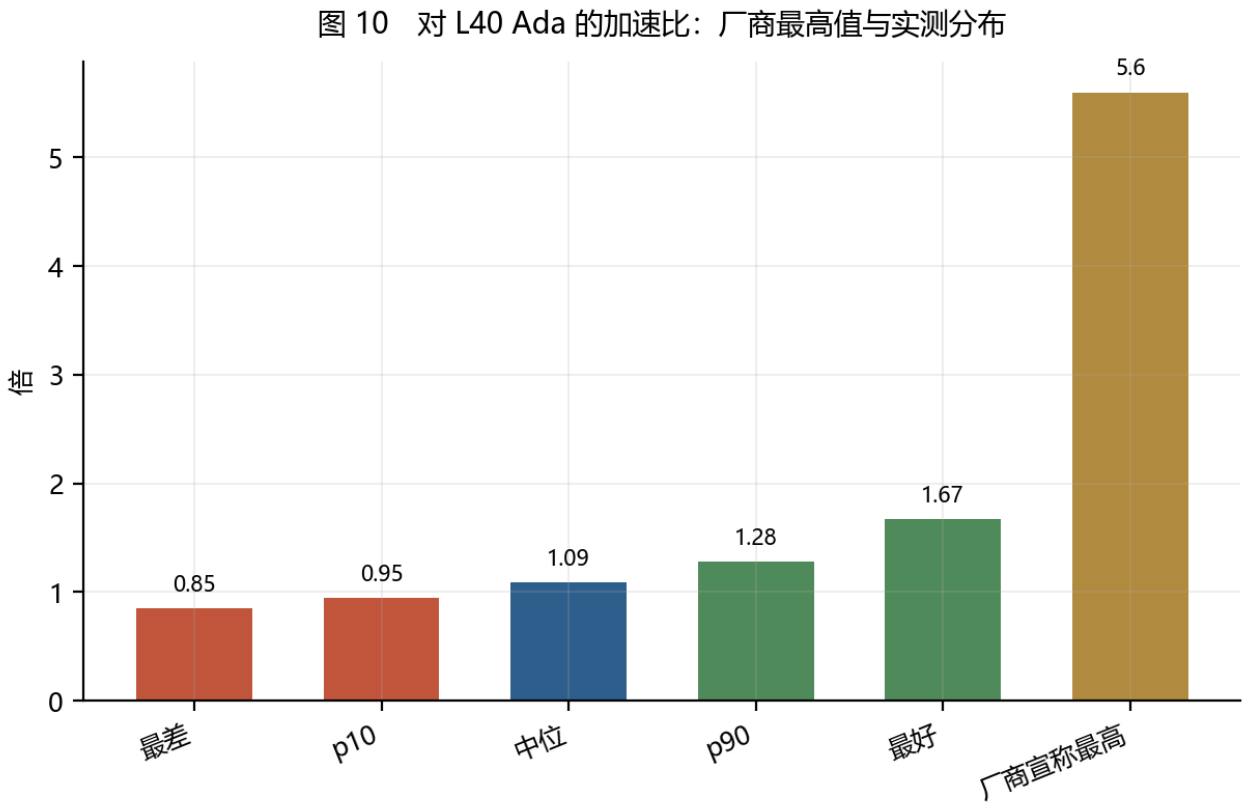


图 10　对 L40 Ada 的加速比：厂商最高值与实测分布。

图 10 把六个倍率画在同一条数轴上，从 0.85 到 5.6 的跨度就是本节的全部论点。

一份多基准实测给出了完整的分布 [c-omni3-vs-l40-median]：
相对 L40 Ada，中位加速比 1.09 倍、胜率 78%，
p10 为 0.95、p90 为 1.28、最差 0.85 倍、最好 1.67 倍。

即两卡显存差 2.0 倍，而实际吞吐差中位仅 1.09 倍。

而厂商的宣传口径是最高 5.6 倍（Llama 3 70B）[c-vgpu-l40s-56]，
分项为 Siemens UFX 2.3 倍、Dassault Abaqus 2 倍、Autodesk Arnold 1.9 倍、Omniverse 3.5 倍。

> ***** 判据
>
> 0.85 倍与 5.6 倍是同一对显卡。
>
> 前者是实测分布的最差值，后者是厂商选的单点最优。
> 两者都不假，但并列才看得出「最高值」离典型值有多远——
> 中位 1.09 倍意味着：换卡的一半场景里，你几乎感觉不到差别。
>
> 故采购判据不能是「最高加速比」，必须是你自己负载上的中位数。

而 p10 为 0.95 倍这个数值得单独说：有 10% 的基准上，新卡比上代还慢。

渲染：这一代是实打实的

并非所有维度都这么平。SPECviewperf 15 上（同为 4K），
相对 RTX 6000 Ada 的几何平均提升 1.47 倍、中位数 1.31 倍 [c-vp15-vs-ada]。

而各项差异极大：enscape-01 达 2.40 倍、blender-01 2.10 倍，
而 unreal_engine-01 仅 1.11 倍。

> ** 判据
>
> 渲染的中位 1.31 倍高于推理的中位 1.09 倍。
> 原因不神秘：渲染是算力受限，推理是带宽受限。
> 这一代算力涨得多、带宽涨得少（1.87 倍），故两类负载的收益不同。
>
> 这与 §3.2 的结论同源：带宽是这张卡的短板，而它恰好是推理的瓶颈。

一条反例：Parabricks 上代际与档位同时被跨越

Parabricks 的 Fastq2bam+DeepVariant 上，Server Edition 比 L40S 快 1.5 倍、
比 H100 快 1.75 倍 [c-parabricks]。

> ** 判据
>
> 这是本文少见的一条「跨代 + 跨档都赢」的负载。
> 它的存在说明：上述所有倍率都是「在该负载上」的，没有一条是「这张卡」的属性。

3.4 预填与解码是两条曲线，不是一条

前面三节都在回答「这张卡多快」。本节要说的是：这个问题本身有歧义。

图 11 同一张卡、同一个模型：预填与解码差 110 倍

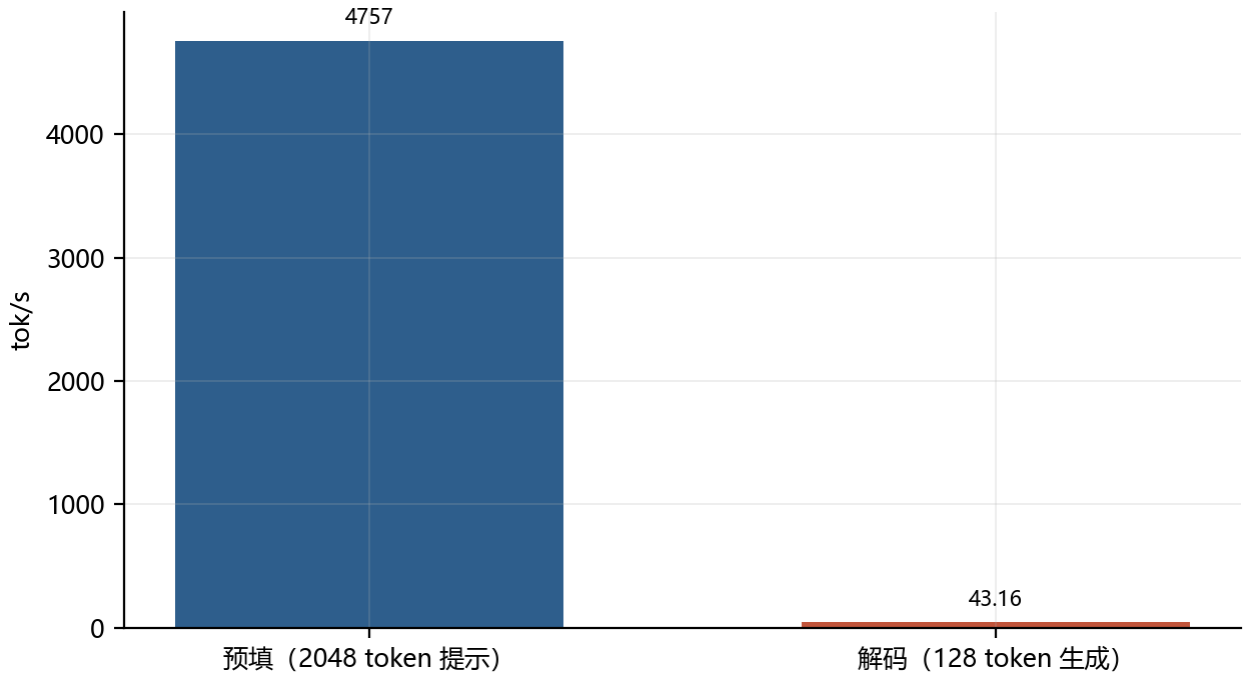


图 11 同一张卡、同一个模型：预填与解码差 110 倍。

图 11 的两根柱子来自同一套 llama.cpp 单流测量、同一张 RTX PRO 6000：
Qwen3.8-27B-Q8_0 的预填 4,757 tok/s，解码 43.16 tok/s [c-llamacpp-prefill][c-llamacpp-decode-parity]。

相差 110 倍。 没有任何一对显卡之间的差距有这个量级。

维度	预填（prefill）	解码（decode）
处理对象	整段提示 可并行	逐 token 生成 串行
瓶颈	算力 FLOPS	显存带宽 GB/s

实测量级（同卡同模型）	4757 tok/s	43.16 tok/s
受功耗档位影响	明显 WS 比 MQ 约快 20%	很小 原文作 similar
同为 1792 GB/s 的两卡	可以差出数倍	接近持平 near-parity
受互连影响	中等	高 EP+TP2 上 PCIe 对 NVLink 差 66%
长输入的代价	随输入长度线性增长	不变
长输出的代价	不变	累积下降 可至 6-9 tok/s
谁更快的答案取决于	算力与功耗档位	带宽与互连

表 7　预填与解码：两条完全不同的性能曲线。

机制：一个并行，一个串行

预填处理整段提示，所有 token 可以同时算——瓶颈是算力。
解码逐 token 生成，每一步都要把整个模型的权重从显存读一遍——瓶颈是带宽。

> ***** 判据
>
> 这两件事对硬件的要求几乎正交，故它们对同一张卡的排序也不同。
>
> 一个只看预填的评测与一个只看解码的评测，可以给出相反的采购建议，
> 而两者都没有说谎。

三条互相印证的证据

其一，同带宽的两张卡，解码持平。
PRO 6000 与 RTX 5090 都标 1,792 GB/s，在 llama.cpp 单流解码下接近持平——
来源自己的说法是「near-parity is the reasonable batch-one decode hypothesis」
[c-llamacpp-decode-parity]。

其二，功耗档位只影响预填。
Max-Q（300 W）与 Workstation（600 W）相比，原文是
「~20% faster prefill on WS, similar decode speed (VRAM/PCIe limited)」
[c-6kw-maxq-prefill]。

即多给一倍功耗，预填快两成，解码几乎不动——因为解码本来就不受算力限制。

其三，互连只在解码上分出高下。
双卡 EP+TP2 上，2 张 PRO 6000（PCIe）对 2 张 B200（NVLink）：
输出吞吐 1,186 对 1,965 tok/s、TPOT 12.82 对 5.63 ms [c-ep-gap]。
多卡解码要每步同步，故互连延迟直接进入关键路径。

代价的形状也不同

「长上下文慢」这个说法同样要拆开。
输入变长只推高预填成本（线性增长），输出变长才压解码吞吐；
而长输出下的解码会累积下降到 6-9 tok/s [c-long-sustained-gen-degrades]。

> *** 判据
>
> 故 §5.4 那张图的两条曲线为什么形状不同，这里给出了原因：
> 一条是输入变长，一条是输出变长，它们加压在不同的瓶颈上。

对选型的直接含义

如果你的负载是长提示、短回答（检索增强、文档问答、代码补全），
那么这张卡的短板（带宽）基本不出现，它是一张很快的卡。

如果是短提示、长回答（自由生成、思维链、agent 循环），
那么几乎全部时间花在解码上，而解码恰好是它相对数据中心卡最弱的一维。

> **** 判据

同一张卡可以是「性价比极高」也可以是「明显不够」，取决于回答有多长。

这就是为什么本文从头到尾拒绝给一个单一的「快多少倍」。

3.5 首字延迟是第三个维度，和上面两个都不同步

§3.4 把「多快」拆成预填与解码两半。这一节再拆出一维：第一个字要等多久，即首字延迟（TTFT，time to first token）。

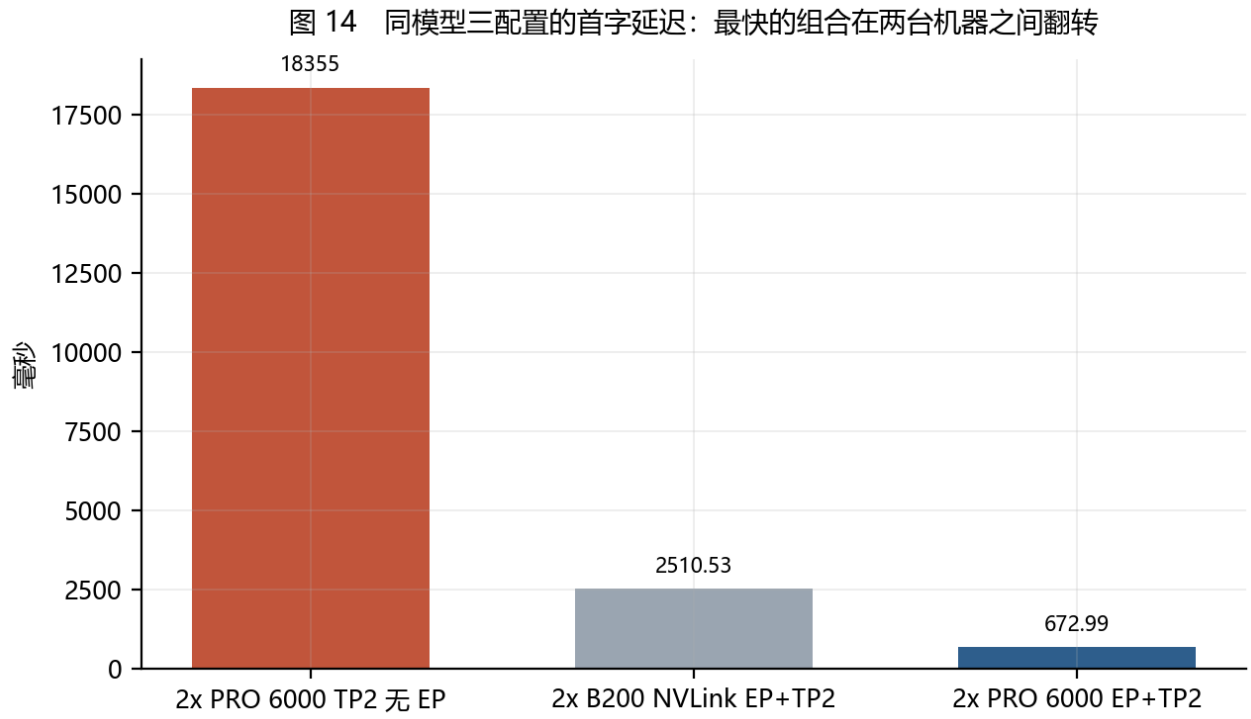


图 14 同模型三配置的首字延迟：最快的组合在两台机器之间翻转。

图 14 的三根柱子是同一个模型（Qwen3.5-35B-A3B）、两种互连下的三种配置。注意纵轴越低越好，且最高的那根比最低的高 27 倍。

配置	TTFT 毫秒	输出吞吐 tok/s	TPOT 毫秒	互连
2x PRO 6000 TP2 无 EP	18354.95	516.44	12.63	PCIe
2x PRO 6000 EP+TP2	672.99	1186.12	12.82	PCIe
2x B200 NVLink EP+TP2	2510.53	1965.18	5.63	NVLink

表 9 首字延迟、吞吐与 TPOT 三者不同步。

三列给出三种排序

表 9 最值得看的地方不是数字，而是三列排出的三种名次：

- 按首字延迟：2x PRO 6000 开 EP（673 ms）快于 2x B200（2,511 ms），快 3.7 倍
- 按输出吞吐：2x B200（1,965 tok/s）快于 2x PRO 6000 开 EP（1,186），快 1.66 倍
- 按TPOT：2x B200（5.63 ms）快于 2x PRO 6000（12.82 ms），快 2.3 倍

***** 判据（本文第三条）

首字延迟由「要等多久才开始算」决定，解码吞吐由「算起来多快」决定，
而这两件事在多卡上由不同的东西支配。

前者受同步次数影响：EP 把整个 MoE 层的激活不再全卡同步，
于是 18,355 ms 变成 673 ms；
后者受互连带宽影响：B200 的 NVLink 让每步同步更快。

EP 的收益几乎全在首字上

同一对 PRO 6000、同一模型，开 EP 前后 [c-ep-ttft]：

	无 EP	EP+TP2	变化
首字延迟	18,355 ms	673 ms	快 27 倍
输出吞吐	516 tok/s	1,186 tok/s	快 2.3 倍
TPOT	12.63 ms	12.82 ms	几乎不变

TPOT 基本没动。 这说明 EP 改善的不是「每个字出得多快」，
而是「开始出第一个字之前的那段等待」。

> *** 判据
>
> 故「开了 EP 快 27 倍」这句话只对首字成立。
> 若用它去描述吞吐，会夸大 12 倍；若用它描述 TPOT，会夸大无穷倍。

而 B200 在首字上反而更慢

同一份基准里，2x B200 靠 NVLink 拿到更高的吞吐与更低的 TPOT，
但首字延迟是 2,511 ms，比 2x PRO 6000 开 EP 的 673 ms 慢 3.7 倍 [c-ep-gap]。

* 这不是 B200 弱，而是两台机器的瓶颈位置不同：
B200 的优势在卡间带宽（每步同步更快），PRO 6000 的优势在单卡容量
（同样的模型可以用更少的卡装下，于是同步更少）。

> **** 判据
>
> 首字延迟与吞吐可以为不同的卡各自最优，且差距都在数倍量级。
>
> 故一个只报吞吐的评测与一个只报首字的评测，会给出相反的采购建议，
> 而两者都没有说谎——这与 §3.4 的结论是同一件事的第二次出现。

单卡部署的天然优势

单卡没有跨卡通信，故 8B 模型的首字延迟是 205 ms，
而多卡或跨节点方案在同一档位上是 520 到 1,320 ms [c-ttft-advantage]。

* 这是 96 GB 的另一个收益，而它与容量无关：能装下就不必分卡，不必分卡就没有首字前的同步等待。

而 MTP（多 token 预测）这类加速技术的收益分布也印证了同一条线：
并发 1 时 P95 首字延迟只从 198 ms 降到 179 ms，
收益集中在解码阶段而非预填阶段 [c-mtp-ttft-barely]。

4 容量成为约束时的推理性能

这一节的所有数字都属于另一类比较：不是「谁在同任务上更快」，而是「谁能跑」。

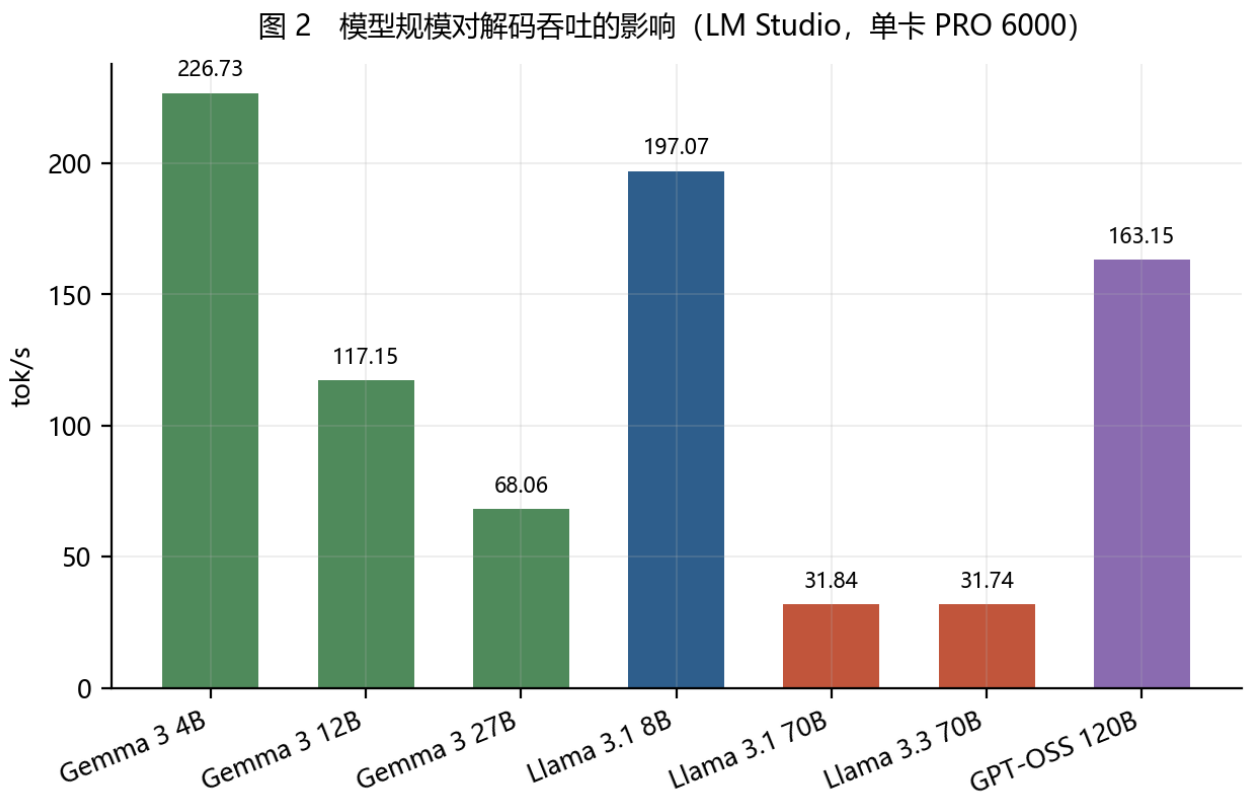


图 2　模型规模对解码吞吐的影响（LM Studio，单卡，SKU 未指明）。

图 2 的横轴是模型规模，纵轴是解码吞吐，两条曲线的间距随规模增大而拉开。

同一 500 词提示、Q4 量化：

模型	规模	tok/s	备注
Gemma 3 4B	4B	226.73	
Llama 3.1 8B	8B	197.07	
Gemma 3 12B	12B	117.15	
Gemma 3 27B	27B	68.06	
Llama 3.1 70B	70B	31.84	Q4_K_S
Llama 3.3 70B	70B	31.74	Q4_K_S
GPT-OSS 120B	120B MoE	163.15	首字 0.193 s

注意 这一组数据来源只写「RTX PRO 6000」，未指明 SKU。 按其 120B 的 163.15 tok/s 与同系列 MQ 的 120B 数据（170.62）接近，推测为 MQ 或 WS，但在来源明确前不应断言。

两种读法都成立，而它们是不同的结论：

- 纵向：4B -> 70B 吞吐降了 7 倍，密模型规模与吞吐近似反比。
- 横向：120B 的 MoE 反而比 70B 密模型快 5 倍。

> *** 故「参数量」不是吞吐的单调预测因子。
> 真正决定解码速度的是每 token 需要搬运的活跃字节数，
> 而 MoE 把「总参数」与「活跃参数」解耦了。

而这一节真正的分界线在这里：RTX 5090 无法加载 120B 模型，甚至常处理不了 70B [c-sr-96gb-unique]。

Llama 3.3 70B Q4_K_S 上，比 5090 提升 928%、比 4090 提升 1141% [c-gn-70b-capacity-domain]。

> 注意注意注意 这三个百分比的正确读法
>
> 它们的量级差距不来自算力，而来自显存容量：
> 到某个点，其它卡显存耗尽，于是「比较」变成了「单边可用」。
> 故它不是一条性能结论，而是一条容量结论。

5 DeepSeek-V4 / V4.1-Flash：本报告实测最多的一条模型线

前四节讨论的是「这张卡」，本节讨论「这个模型」。这样做是因为 DeepSeek-V4/4.1-Flash 在档案里有 50 条主张、跨 6 种硬件配置，是唯一一条能在同一张卡上横向看到「预填 / 解码 / 长上下文 / 投机解码」四个维度的模型线。

5.1 先给结论：一个模型，三个数量级

把档案里所有 DeepSeek-V4-Flash 的数字放在一起，会得到一个看起来荒谬的结果：

场景	硬件	数值
单流解码（原生 FP8 热态）	2x DGX Spark TP2	44 tok/s
单流解码（Q8 无投机）	2x PRO 6000	46 tok/s
单流解码（300 W 目录值）	1x PRO 6000 @300W	102.7 tok/s
解码（同批预填测试）	2x PRO 6000 WS TP2	133.7 tok/s
预填 8k（混合方案）	2x PRO 6000 WS TP2	13,811 tok/s
预填 128k（混合方案）	2x PRO 6000 WS TP2	12,182 tok/s

从 44 到 13,811，跨 三个数量级。而它们都是真的。

> *** 判据
>
> 这不是数据矛盾，而是测法不同：
> 预填（prefill）处理的是整段提示，可并行；
> 解码（decode）逐 token 生成，受显存带宽约束。
> 两者在同一个模型上天然差 100 倍以上。
>
> 故「DeepSeek-V4-Flash 的吞吐是多少」这个问题，必须先回答「预填还是解码」。

表 3 把这九组数据按场景、硬件、SKU、证据等级并列，每行都能回到一条主张。

场景	硬件	数值	单位	SKU	证据等级
单流解码（Q8 无投机）	2x PRO 6000	46	tok/s	未指明	测量级
单流解码（原生 FP8 热态）	2x DGX Spark TP2	44	tok/s	未指明	测量级
单流解码（300W 目录值）	1x PRO 6000 @300W	102.7	tok/s	300W 档	测量级
预填 8k（混合方案）	2x PRO 6000 WS TP2	13811	tok/s	WS	测量级
预填 64k（混合方案）	2x PRO 6000 WS TP2	13201	tok/s	WS	测量级

预填 128k（混合方案）	2x PRO 6000 WS TP2	12182	tok/s	WS	测量级
解码（同批预填测试）	2x PRO 6000 WS TP2	133.7	tok/s	WS	测量级
最大上下文（满 1048576）	单卡	1048573	token	未指明	测量级
对比：Spark 比 PRO 6000 慢	2x DGX Spark 对 2x PRO 6000	6	倍	未指明	测量级

表 3　DeepSeek-V4 / V4.1-Flash 在 RTX PRO 6000 上的全部实测。

5.2　预填：五次改动，单调改善

图 5　DeepSeek-V4-Flash 预填吞吐：五次优化递进

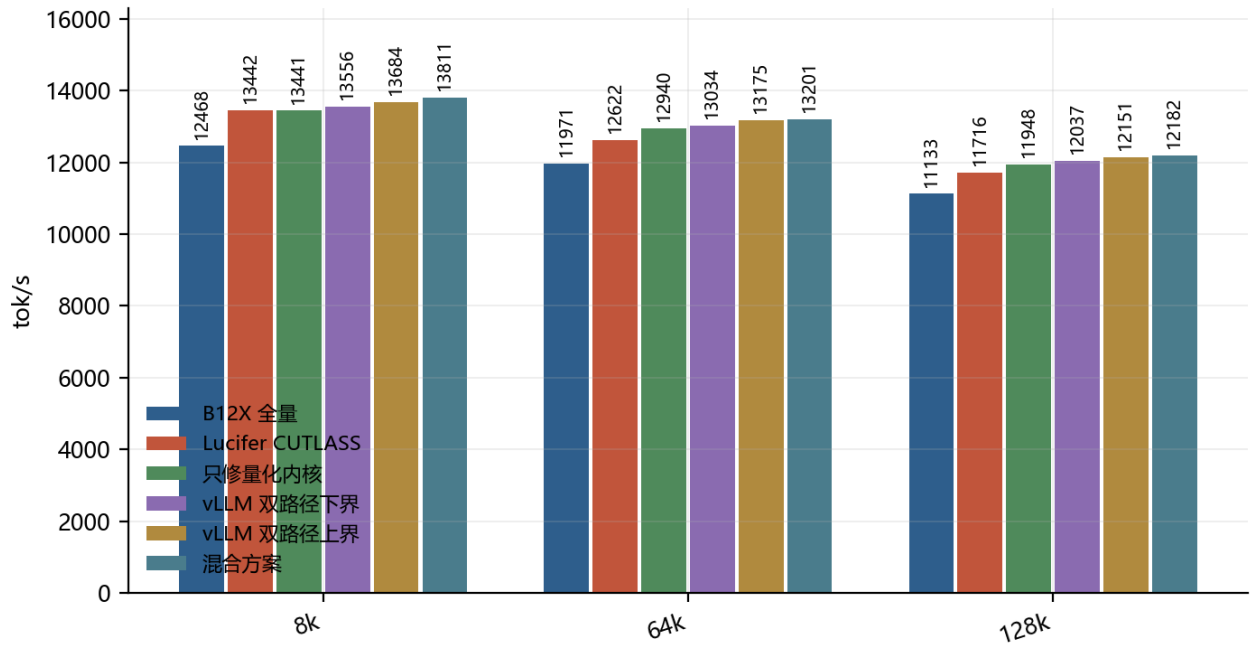


图 5　DeepSeek-V4-Flash 预填吞吐：五次优化递进。

图 5 按优化次序排列，五次改动全部单调改善，没有任何一次回退。

同一台双卡 RTX PRO 6000 WS（TP2、force-A8 MoE、独立预填、max_num_seqs=1、fp8 KV、block 256）上，五个逐步改动的版本 [c-df-rtx6k-baseline]：

上下文	B12X 全量	Lucifer CUTLASS	只修量化内核	vLLM 双路径（区间）	混合方案
8k	12,468	13,442	13,441	13,556 至 13,684	13,811
64k	11,971	12,622	12,940	13,034 至 13,175	13,201
128k	11,133	11,716	11,948	12,037 至 12,151	12,182

三个可读出的东西：

其一，总收益稳定在 9%-11%。 8k 提升 10.8%，128k 提升 9.4%。

其二，收益不来自单一改动。 从 B12X 到 Lucifer CUTLASS 拿到 7.8%（8k），再「只修量化内核」在 8k 上几乎是零（13,442 到 13,441），却在 64k 上拿到 2.5%（12,622 到 12,940）。
同一改动在不同上下文长度上的收益不同。

其三，有一个改动是单调的。 「+ vLLM 双路径」与「混合方案」在三档上都改善，而这是唯一一组在三档上都不倒退的改动。

** 判据

当一个配置的收益随上下文长度变化时，
「这个优化提升了 N%」这句话必须带上下文长度才有意义。
本报告在 8k 上说「+10.8%」、在 128k 上说「+9.4%」，

两者都是同一个改动的结果，但它们是两个数字。

5.3 解码：在 300 W 档位上的横向位置

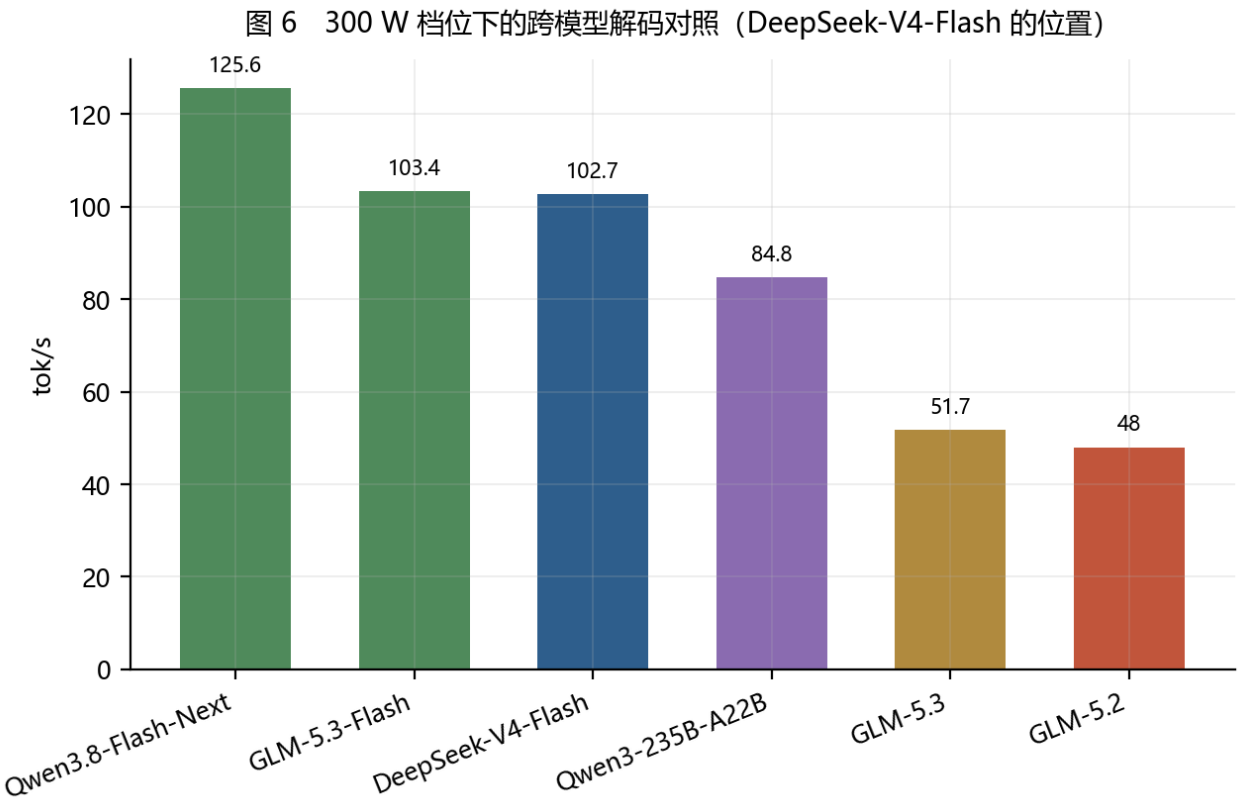


图 6 300 W 档位下的跨模型解码对照。

图 6 的六根柱子都在同一功耗与同一上下文下测得，故它们之间的差异只反映模型本身。

单卡 300 W、pp2048 / tg128、单客户端下的一份跨模型表 [c-ds-300w-catalog]：

模型	解码 tok/s	预填 tok/s
Qwen3.8-Flash-Next	125.6	7,795
GLM-5.3-Flash	103.4	8,718
DeepSeek-V4-Flash	102.7	6,341
Qwen3-235B-A22B	84.8	4,808
GLM-5.3	51.7	2,200
GLM-5.2	48.0	2,197

DeepSeek-V4-Flash 在解码上排第三，落后 Qwen3.8-Flash-Next 18.2%、
落后 GLM-5.3-Flash 0.7%，领先 Qwen3-235B-A22B 21.1%。

而它在预填上排第四：6,341 落后 GLM-5.3-Flash 27.3%、落后 Qwen3.8-Flash-Next 18.7%。

*** 一个反直觉的发现

同一个模型在解码榜和预填榜上的排名不同。
GLM-5.3-Flash 解码只比它快 0.7%（在噪声内），预填却快 27.3%。

故「A 模型比 B 模型快」这句话，
连「同一个模型」内部都不成立：它取决于你问的是预填还是解码。

5.4 长上下文的真实代价：不是上下文，是输出长度

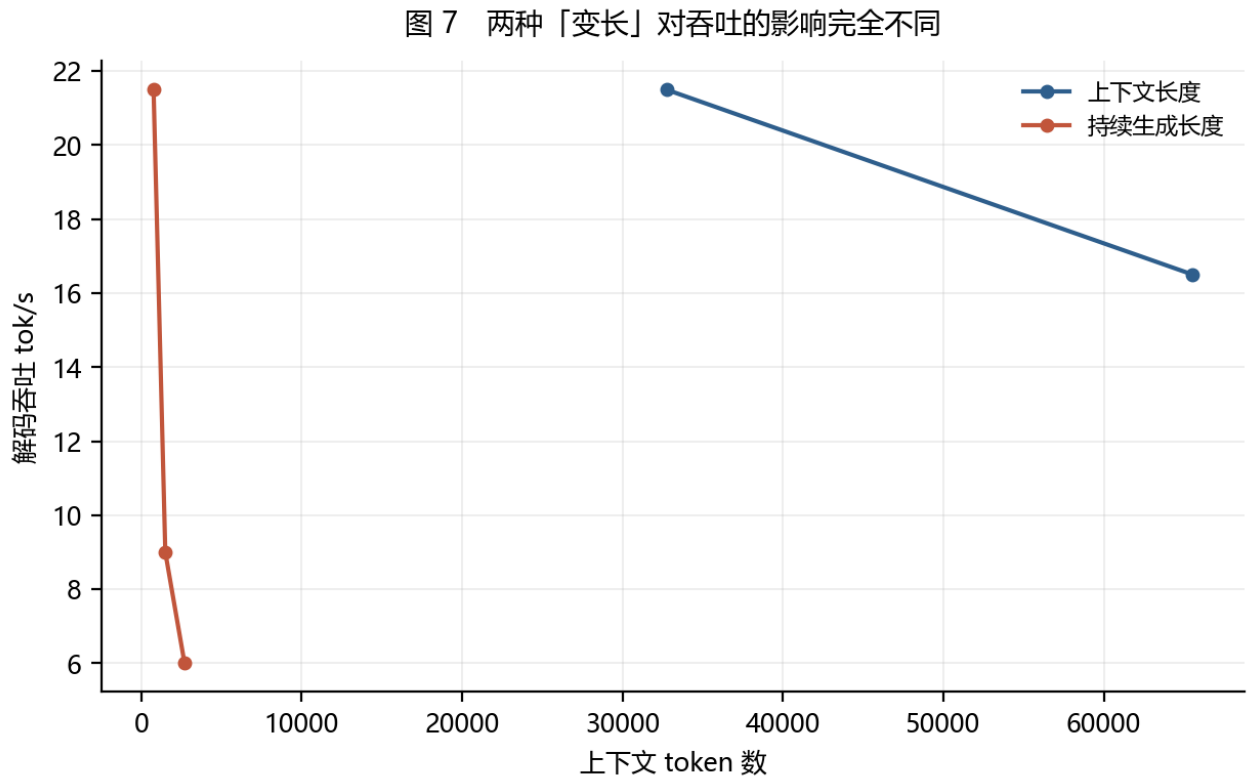


图 7　两种「变长」对吞吐的影响完全不同。

图 7 的两条曲线一个缓慢下降、一个断崖下跌，这就是「长上下文慢」这个说法必须拆开的原因。

档案里有一条此前完全没有记录的性能现象，而它不是关于上下文长度的 [c-long-sustained-gen-degrades]：

- 32K 上下文、768-token 基准三次：19.97 / 21.18 / 23.31，均值 21.49 tok/s
- 64K 上下文、同样基准：16-17 tok/s（降 23%）
- 而通过 Open WebUI 流式做 1,500-2,700 token 的持续生成时：掉到约 6-9 tok/s

降幅 58%-72%，远大于上下文的 23%。

> ***** 判据
>
> 「长上下文慢」与「长输出慢」是两件事，而后者严重得多。
> 而多数基准只测短输出的稳态解码，于是这个现象在所有基准里都不可见。
>
> 故「tok/s」这个数必须带「生成多长」才有意义。
> 一个 21.49 tok/s 的基准成绩，与用户在对话里真实感受到的 6-9 tok/s，
> 差 3 倍，而两者测的是同一个模型、同一台机器。

注意：这组数据的硬件是 双 DGX Spark（2x GB10），不是 RTX PRO 6000。
故它证明的是模型行为，不是这张卡的性能。但它对推理性能的意义是通用的。

5.5　同条件对照：Spark 慢 6 倍，而差距不来自架构

一条同条件对照给出了量级 [c-spark-6x-slower]：
2 张 DGX Spark 做 TP2，在 DeepSeek-V4-Flash 上比 2 张 RTX 6000 做 TP2 慢约 6 倍。

而两者共享同一批 SM120 核心。故差距不来自架构，来自显存带宽与每卡功耗。

> ** 判据
>
> 这是本文最干净的一条「控制变量」证据：
> 同一 compute capability、同一模型、同样 TP=2，只换内存子系统与功耗预算，结果差 6 倍。
>
> 故在推理场景里，「架构代际」不是主要变量，带宽与功耗才是。

5.6 百万上下文：可行，但瓶颈不是显存

DeepSeek-V4-Flash 在 llama.cpp 上成功生成了第 1,048,573 个 token，
即跑满 1,048,576 上下文 [c-1m-feasible]。

而档案里有两条互相印证的解释，说明为什么只有它能做到：

其一，依赖模型结构。 具备稀疏注意力 / indexer 的模型（正是 DeepSeek-V4-Flash）
可以做到；而 MiMo V2.5 只是交替 SWA 与非 SWA 层，会尝试为完整上下文分配 KV，
单次请求就要 68,625 MiB 而 OOM。

其二，真实瓶颈是 32 位整数溢出。 当 n_kv x n_ubatch 越过 2^{32} 边界时崩溃；
具体边界是 262,144 x 16,384 = 2^{32}。
修复方式是把 flash_attn_mask_to_KV_max 的步长参数从 32 位 int 改为 64 位 size_t，
经第三方在相同设置下验证，处理 334,585 个新 token（约 1.5 小时）无崩溃。

> 注意注意注意 判据
>
> 「长上下文 OOM」这个诊断在 262,144 这个点上是错的：
> 它不是显存不够，而是整数溢出。
> 而这两者的表象完全相同（进程崩溃），故只能靠算那个乘法来区分。

5.7 而它在 SM120 上曾经完全跑不起来

必须记录的一条：纯上游 vLLM 在 SM120 上完全无法服务 DeepSeek-V4，
且被逐层剥离出四个互相独立的阻塞点 [c-ds-upstream-cannot-run]。

其中最深的一个：mHC（Manifold-Constrained Hyper-Connections）层调用
tf32_hc_prenorm_gemm，而 DeepGEMM 树里只有 SM90 与 SM100 的实现——
sm100_* 用 TMEM / tcgen05.mma / cluster multicast，sm90_* 用 WGMMA，
不存在 sm120_* 变体。报错发生在 hyperconnection.hpp:56。

而现场报告同时给出了一个乐观判断：SM120 原生支持 warp 级
mma.sync.aligned.m16n8k32（SM80 时代）外加 TMA，故一个朴素移植
「在功能上是正确的……吞吐不是最优，但能解锁整个 V4 家族」。

> ** 判据
>
> 「这个模型能在 Blackwell 上跑」不是一个布尔值，而是一条逐层清单：
> 权重加载、量化配置、MoE 分派、注意力后端、以及 mHC。
> 前四项都过了，第五项断言失败。
>
> 故「支持」这个词在没有清单的情况下没有信息量。

6 96 GB 真正买到的是什么：上下文预算

如果 96 GB 买的不是速度，那它买的是什么？本节给出可以算出来的答案。

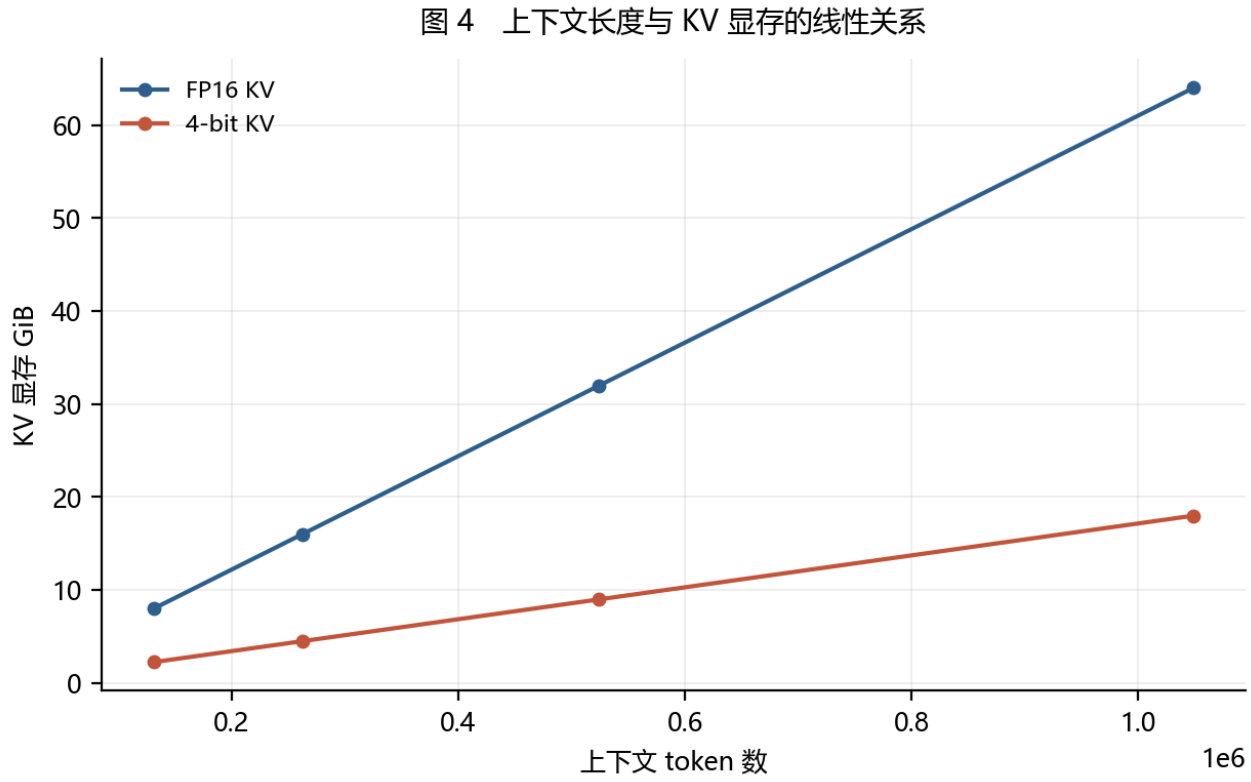


图 4　上下文长度与 KV 显存的线性关系。

图 4 的直线斜率就是那个 18.3 KiB 的乘数，四条参考线分别对应四种精度的 KV 格式。

关键的乘数是每 token 的 KV 字节数。这个数在本报告里长期缺失——68 处「上下文 与 显存」的表述中，只有 1 处给了它。

两个独立来源给出了同一个值：

- Bonsai 2 27B README：FP16 KV cache 64 KiB per token（100K 约 6.3 GiB）
- 本档案的压缩记录（见 §6）：18.3 KiB/活跃 token、相对 BF16 3.50x => 18.3 x 3.50 = 64.05 KiB

两者相差 0.08% [c-two-independent-models-agree-on-64-kib-per-token]。同一张表还给了相对 FP8 1.75x」=> 18.3 x 1.75 = 32.02 KiB，即 FP8 恰为 FP16 的一半。三个精度构成一条等比链：FP16 64 / FP8 32 / 压缩 18.3 KiB。

> *** 判据
>
> 当一个常量由两个完全不同的模型（不同层数、不同头数）独立算出相同的值时，
> 它说明的不是「这两个模型一样」，
> 而是「这个量级被架构约束住了」。

按 64 KiB/token 换算：

上下文	FP16 KV	4-bit KV（18 KiB）
131,072	8.0 GiB	2.25 GiB

262,144	16.0 GiB	4.5 GiB
524,288	32.0 GiB	9.0 GiB
1,048,576	64.0 GiB	18.0 GiB

换算依据 [c-fp16-kv-cache-is-64-kib-per-token] [c-256k-context-costs-16-gib-of-kv] [c-4bit-kv-cuts-per-token-cost-to-18-kib]。

这张表改变了三个此前说不清的问题。

其一，256K 上下文不是瓶颈。 它只吃 16 GiB，在 96 GB 上占比不到 1/6。

其二，1M 上下文才逼近上限。 64 GiB 的 KV 之后只剩 32 GiB 装权重——于是问题从「显存够不够放 KV」变成「剩下的够不够放模型」。

其三，KV 量化在这张卡上是一个「不需要」的优化。 4-bit 在 1M 上省下 46 GiB，但那 46 GiB 在 96 GB 上并没有对应的瓶颈。

> 注意注意注意 一条必须同时给出的限制
>
> 「某模型能跑 N 上下文」这句话不能跨模型迁移 [c-a-context-capability-does-not-transfer-between-models]。
> 因为 显存占用 = 权重 + N x 每 token 字节数，
> 而后一项由层数、KV 头数、头维度与 KV 精度共同决定。
> 本文实测的两个模型就差 3.5 倍（64 vs 18.3 KiB）。
>
> 故「这张卡支持 N 上下文」应一律改写为「在模型 M 上支持 N」。

这条限制的一个直接应用：本报告曾记有「单张，320K 上下文只用 44 GB 显存」。按 64 KiB/token 反推，320K 本身就要 20.0 GiB 的 KV，故余下约 24 GB 才是权重——那是一个约 20 GB 权重的小模型的结果，不是这张卡的通用能力。原文已在该处加注更正，旧文保留。

7 五个让测量失效的陷阱

本节记录的是方法，不是结论。它们全部来自这批资料的采集过程，每一条都曾造成过一个错误数字。

7.1 HTTP 200 不等于拿到了内容

抓取 TechPowerUp 的 rtx-pro-6000.c4290 返回 HTTP 200，响应体 118,611 字符——但 <title> 是「AMD Radeon AI PRO R9700 Specs」，且带 noindex,nofollow。正文纯文本只有 335 字符，搜「96 GB」零命中。

> 判据：当反爬策略选择「返回一张无关但完整的页面」时，它比 403 危险得多——
> 因为 403 会让调用方停下来，而 200 会让它把无关内容当成答案。
> 故抓取日志的最小字段应是「状态码 + 标题 + 目标关键字命中数」三项。

7.2 参数「存在但无效」

Bonsai 的推理档位有 xhigh / medium / low 三档，但原文写着：low 不被支持，选中时行为接近 xhigh [c-xhigh-is-default-and-low-is-unsupported]。

> 判据：当一个参数「存在但无效」时，它比「不存在」更危险——
> 因为调用方会以为自己调低了成本，而实际行为与最高档相同。

7.3 能力数字缺少模型规模

见 §5 末尾的 320K/44 GB 例子。同一个数字在加上模型规模前后是两条完全不同的结论。

7.4 零提及的文档被整批跳过

Bonsai README（24,840 字节）里 RTX PRO / 96 GB / 5090 / 4090 的出现次数全是 0 [c-the-b

onsai-readme-has-no-pro-6000-data]。按「是否提到目标硬件」筛选，它会被整个丢掉——而它恰恰是 §5 那个关键乘数的来源。

> 判据：读文档的目的不应只是「找数字」，还包括「找乘数」。

7.5 型号名当作配置名

见 §1.1。这是本文新增的一节，也是这批资料里代价最高的一条：227 条主张因此无法定位 [c-227-of-2233-claims-do-not-name-a-sku]。

7.6 五个陷阱的汇总

陷阱	表现	为何会骗人	如何识别
HTTP 200 诱饵页	gpu-specs 返回 AMD R9700 页面	状态码正确但内容是另一个产品	校验标题是否含目标名
参数存在但无效	low 推理档等于 xhigh	调用方以为降了成本	对比 low 与 xhigh 得到零差异
能力数字无模型规模	320k 上下文只用 44 GB	被读成显卡能力而非某模型结果	反推 KV 后看剩余权重
零提及文档被跳过	25 KB README 无 PRO 6000 字样	丢掉了跨硬件通用的常量	按可否换算排序检索
单位不可通约	GPU-seconds 与 tok/s 并列	分母与所含项都不同	禁止同表比较

表 2　五个让测量失效的陷阱：表现、为何会骗人、如何识别。

8 渲染负载的对照：SKU 排序会反转

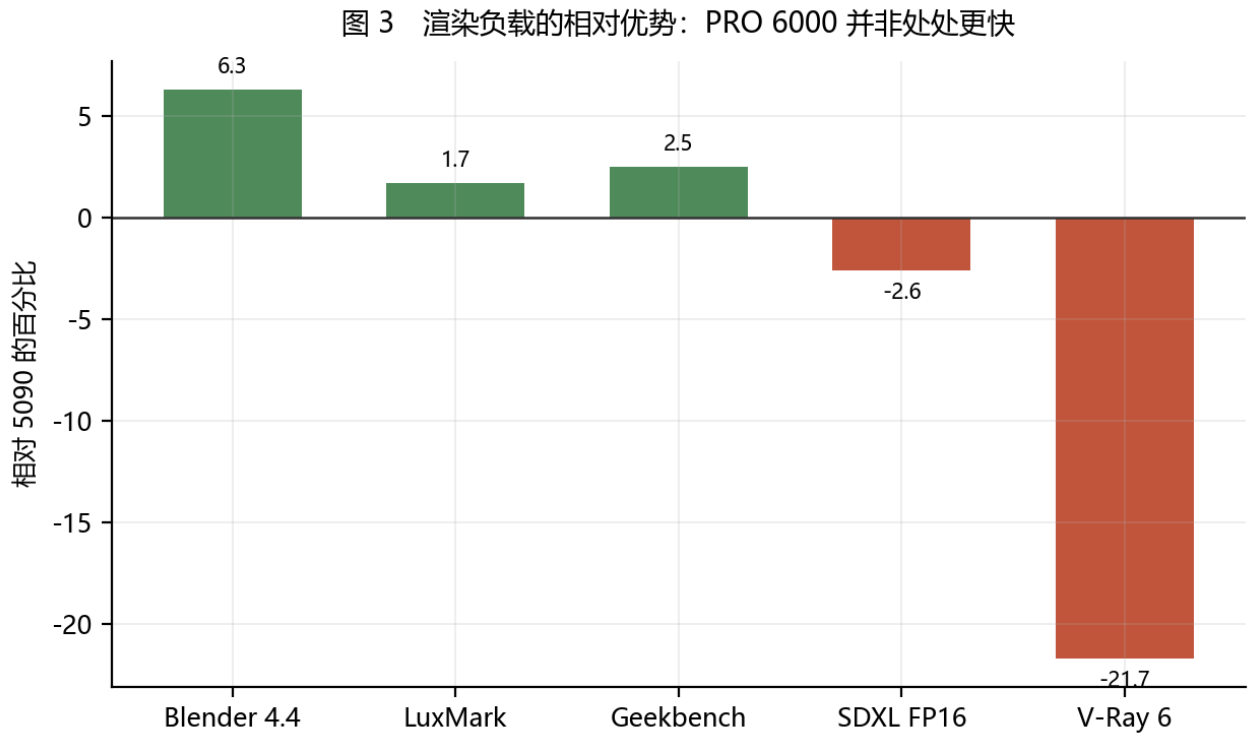


图 3　渲染负载的相对优势：并非处处更快，且 SKU 排序会反转。

图 3 把六个渲染器的相对优势画在同一尺度上，正负号的分界正是「谁更快」这个问题的答案分裂处。

负载	相对 RTX 5090
Blender 4.4（WS，三场景均值）	+6.3%
LuxMark（WS）	+1.7% ~ +5.0%（claim 记下限/上限）
Geekbench（WS）	+2.5%
SDXL FP16（WS）	-2.6%
V-Ray 6（WS，vpaths）	-21.7%

数据来源 [c-sr-renderer-split] [c-sr-blender-narrow] [c-sr-vray-loses]。

V-Ray 6 上 RTX 5090 以 14,764 vpaths 领先 WS 版的 12,128 [c-sr-vray-loses]。

而 SKU 排序在这里也反转了 [c-sku-order-inverts-between-renderers]：

基准	WS	Server	Max-Q	5090	结论
Blender Open Data	18,571	18,580	18,678	18,747	四者极差 0.9%
OctaneBench 2025.2	1750	1641	1601	—	WS > SE > MQ
V-Ray 6	11,994	14,827	—	10,116	SE 反超 WS 23.6%

> ***** 判据
>
> 当同一批 SKU 在三个基准上给出三种排序时，
> 「哪个 SKU 更快」这个问题本身没有答案——
> 只有「在哪个基准上更快」有答案。
>
> 故凡见「A 版比 B 版快」，必须同时给出基准名与差值，缺一不可。

而 §4 那个 928% 与这里的 -21.7% 并存，说明：这张卡的价值曲线不是「更快」，而是「在容量边界附近突然可用」。

9 能耗与成本：买得起不等于用得起

这一章要回答的是最实际的一问：值不值得买。
而它会给出一个自我矛盾的答案——八个指标里，这张卡赢两个、输六个。

9.1 按芯片成本排，它最便宜

图 12 TCO 每芯片每小时：这张卡最便宜

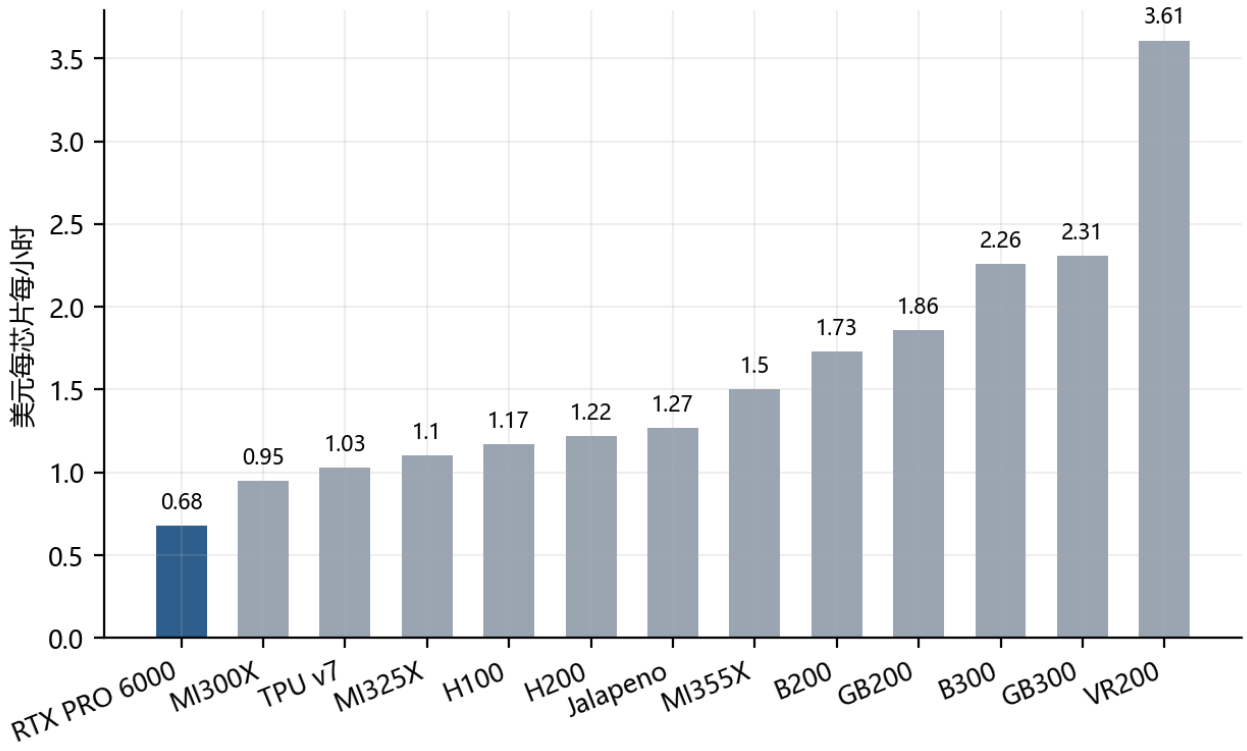


图 12 TCO 每芯片每小时：这张卡最便宜。

图 12 按 TCO 每芯片每小时排列 13 张加速器，RTX PRO 6000 的 0.68 美元最低，是 GB300 的 2.31 美元的 29%——便宜 3.4 倍 [c-ix-paradox]。

注意 注意这一维越低越好，而它是本文唯一一张「本卡领先」的成本图。

9.2 按 token 成本排，它最贵

图 13　每百万 token 成本：随交互性要求上升，而对照卡恒定

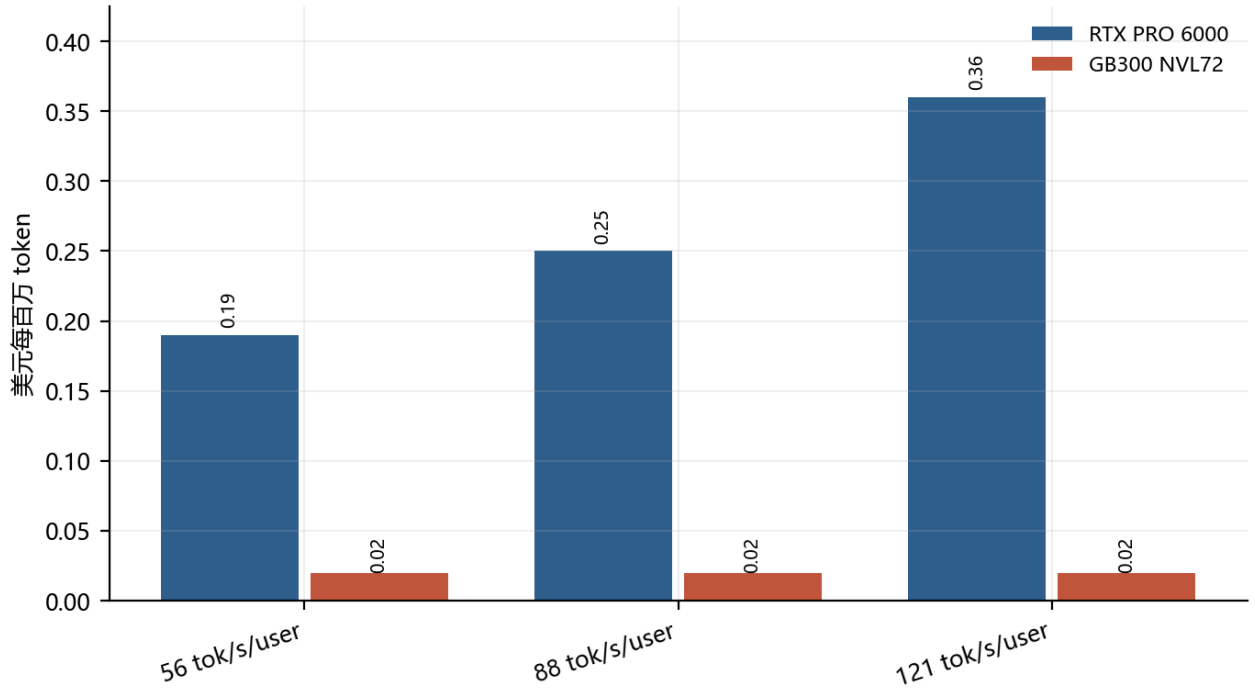


图 13　每百万 token 成本：随交互性要求上升，而对照卡恒定。

芯片	每芯片每小时成本（美元）	每百万 token 成本（美元）	该交互性下的并发数
RTX PRO 6000	0.68	0.19	10
MI325X	1.1	未给出	未给出
H100	1.17	未给出	未给出
H200	1.22	未给出	未给出
B200	1.73	未给出	未给出
GB300	2.31	0.02	约 2983

表 5　买得起不等于用得起：每芯片成本与每百万 token 成本。
按芯片逐行对照，可以看到「每芯片每小时」这一列它最低，而「每百万 token」这一列只有对照卡给了数、且相差一个量级。

图 13 把三组柱子并排，可以看到对照卡的三根完全等高，而这张卡的三根逐级抬升。

同一份来源、同一个模型（Qwen 3.5 397B-A17B）、同一精度（FP4），
目标交互性从 56 提到 121 tok/s/user 时 [c-ix-perdollar]：

- RTX PRO 6000：$0.19 -> $0.25 -> $0.36 每百万 token
- GB300 NVL72：$0.02 -> $0.02 -> $0.02

对照卡的成本是平的，而这张卡随要求变高而上涨。

原因是并发：同一交互性点（56 tok/s/user）下，
GB300 NVL72 能同时服务约 2,983 路请求，而这张卡约 10 路 [c-ix-paradox]。

***** 判据（本文第二条）

低芯片成本无法弥补低并发。

一张便宜 3.4 倍的卡，若每单位时间能卖出的 token 少 298 倍，

那么它的单位 token 成本会贵 9.5 倍。
「买得起」与「用得起」是两个完全不同的判据，且方向相反。

指标	RTX PRO 6000	对照卡	谁更优	口径
TCO 美元每芯片每小时	0.68	GB300 为 2.31	RTX 为 29% 即便宜 3.4 倍	来源直接给出
每百万 token 成本 56 tok/s	0.19 美元	GB300 为 0.02 美元	GB300 更省	来源直接给出
每百万 token 成本 121 tok/s	0.36 美元	GB300 为 0.02 美元	GB300 更省	来源直接给出
成本效率差距 56 tok/s	1.0	高出 1047%	GB300 更优	来源原话
同交互性下并发 56 tok/s	约 10	GB300 约 2983	GB300 高约 298 倍	来源直接给出
每美元性能	领先 2.1 倍	落后	H100 NVL 为参照	来源直接给出
每瓦性能	落后约 1.5 倍	领先	H100 为参照	来源直接给出
单卡总能耗 SDXL	1.35 Wh	5090 为 1.16 Wh	5090 略优	来源直接给出

表 8　六个成本与能效指标，指向不同的卡。

9.3　一处必须如实写出的口径差异

来源对 56 tok/s/user 这一点的原话是「GB300 NVL72 的成本效率高出 1047%」[c-ix-perdollar]。

而按两数直接相除：0.19 除以 0.02 再减 1，等于 850%。

1047% 对应 11.47 倍，850% 对应 9.5 倍。 两者差 20%。

*** 判据

「成本效率」这个词有多种口径：可以是成本之比，
也可以是「同样预算能买到多少 token」，中间可能含别的时间折算。
而来源没有展开它是哪一种。

本文两个数都写，并注明哪个是来源的、哪个是我按两数算的。
把不吻合的地方隐去，比算错更糟——因为下一个人会以为它对得上。

9.4　能效：另一个方向相反的指标

在 SPECworkstation 类负载上（WS 版），整机平均功耗 918.5 W、
峰值 1,036.3 W、空闲 152.3 W；SDXL FP16 的 5.3 秒测试区间总能耗 1.35 Wh [c-sr-power-918w]。

卡	同负载总能耗
RTX PRO 6000 WS	1.35 Wh
RTX 4090	1.35 Wh
RTX 5090	1.16 Wh
RTX 6000 Ada	1.76 Wh

评测方指出，同为 GB202 芯片且不同 SKU 的新 Blackwell 卡在该负载下能效特征非常接近，
能耗差异主要来自 TDP 差异 [c-sr-power-converged]。

而放到机架密度上看，方向又反了一次：H100 约 1.5 倍性能每瓦 [c-slac-power-favors-h100]。

*** 判据

于是同一张卡在三个指标上分别排第一、倒数第一、和倒数第二：
每芯片成本最低、每 token 成本最高、每瓦性能落后 1.5 倍。

三者都是真的，选哪个取决于你的约束是资本、是吞吐、还是电。

9.5 价格本身也是一个陷阱

价格必须按 SKU 分开记 [c-sr-price-8500]：WS 首发 $8,500，当前街价 $17,999——
两者相差一倍以上，而方向与「首发价 vs 一年后街价」相反，
故更可能是两个来源采集口径不同（首发建议价 vs 稀缺期市场价），而不是价格真的上涨了一倍。

** 判据

当两个来源对同一商品给出相反方向的价格差时，先怀疑口径，再怀疑市场。

10 结论与未解问题

结论

1. 「这张卡多快」不是一个问题，是三个问题。
预填 4,757 tok/s、解码 43.16 tok/s、首字延迟 673 毫秒，是同卡同模型同测量的三个数，
前两者差 110 倍；
而首字与吞吐的排序还会在不同的卡之间翻转：2 张 B200 吞吐高 1.66 倍、
TPOT 低 2.3 倍，首字却慢 3.7 倍 [c-llamacpp-prefill][c-llamacpp-decode-parity][c-ep-ttft][c-ep-gap]。
前者受算力限制、后者受带宽限制，故任何单点「加速比」都必须注明是哪一半。

2. 这个产品名不是一个配置，而是三个。 同一模型同一命令下 MQ 比 WS 慢 12.9%-13.1%；同功耗点 300 W 上 SE 比 WS 快 38% [c-sku-choice-changes-tok-s-by-13pct]。而「比 5090 快还是慢」的答案随之翻转：WS 快 5%，MQ 慢 12%。

3. 这张卡买的不是速度。 容量不受约束时，WS 与 RTX 5090 的 token 速率差距只有 1.5%-5.9% [c-sr-token-vs-score]。

4. 它买的是「在容量边界上仍然可用」。 120B 模型上 5090 无法加载，而它以 163.15 tok/s 完成 [c-sr-96gb-unique]。这个差异的性质是可行性，不是速度。

5. 96 GB 的实际形态是上下文预算。 按 64 KiB/token，256K 需 16 GiB、1M 需 64 GiB [c-256k-context-costs-16-gib-of-kv]。后者的约束不是 KV 而是剩余权重空间。

6. 「买得起」与「用得起」方向相反，而两个数都是真的。
TCO 每芯片每小时 0.68 美元，13 张加速器里最低，是 GB300 的 29%；
但每百万 token 成本 0.19 到 0.36 美元，而 GB300 NVL72 三档恒为 0.02。
原因不是性价比，是并发：同交互性下 GB300 服务约 2,983 路、这张卡约 10 路 [c-ix-paradox][c-ix-perdollar]。
低芯片成本无法弥补低并发。

7. 渲染领域的结论不可外推，且 SKU 排序在基准间反转。 SE 在 V-Ray 上领先 WS 23.6%，在 OctaneBench 上落后 6.2%，在 Blender 上与 5090 打平 [c-sku-order-inverts-between-renderers]。

8. 「比上代提升 N 倍」这句话，选不同的基线可以差 20 倍。
对 L40 Ada 的实测中位是 1.09 倍、最差 0.85 倍；对同一对卡的厂商宣称最高是 5.6 倍；
L2 缓存相对 RTX A6000 是 21.3 倍 [c-omni3-vs-l40-median][c-vgpu-l40s-56][c-l2-cache]。
故采购判据不能是「最高加速比」，必须是你自己负载上的中位数。

9. 「与 H100 比」不是一个问题，是四个问题。 每美元性能赢（便宜 2.1 倍）、
每瓦性能输（落后约 1.5 倍）、每 token 成本大输（差约 9.5 倍）、
单流解码输（带宽差 1.87 倍）。四个指标指向不同的结论 [c-slac-h100-vs-rtx][c-slac-power-favors-h100][c-ix-paradox][c-hbm-bw-gap]。
故本文不给「谁更好」的排名，只给「在哪个约束下更好」。

10. 同一个模型在预填榜与解码榜上的排名不同。 DeepSeek-V4-Flash 在 300 W 档的解码上排第三
（102.7 tok/s，落后第一名 18.2%），但在预填上排第四（6,341 tok/s，落后第一名 27.3%）[c-ds-300w-catalog]。
故「A 模型比 B 模型快」这句话，连「同一个模型」内部都要先问是预填还是解码。

11. 「长输出慢」比「长上下文慢」严重得多。 上下文 32K 到 64K 只降 23%，
而持续生成从 768 token 拉到 1,500-2,700 token 会掉到 6-9 tok/s，降幅 58%-72%
[c-long-sustained-gen-degrades]。而多数基准只测短输出，故这个现象在基准里不可见。

12. 全部数字最高只到「测量级」。 本文没有一条结论达到复现级——因为没有任何一条曾在第二台机器、同一 SKU 上被独立重测。

未解问题

#	问题	类别
1	§3、§4 两组基准数据的确切 SKU（来源未写明）	recoverable
2	未打补丁的原版 llama.cpp 在同一 SKU 上的数字	recoverable
3	SGLang 用 vLLM 那套参数在同一批 4 卡上的结果	recoverable
4	llama-bench -r 3 是否把受预热污染的第一轮算进平均	recoverable
5	官方 Known Issue「multi-GPU on RTX Pro 6000」的具体内容	context
6	同一量化在 sm_120 与 sm_100 上的成对对照	context

> * 一个已经修掉的结构性缺陷
>
> 上一版本文的 SKU 纪律是事后加的散文——227 条旧主张不带 SKU 字段。
> 本轮把它变成了字段：claims.csv 新增 sku 列，校验器每次运行都报告
> sku_unspecified 的当前值（现为 244）。
>
> 关键差别不在「多了一列」，而在这个数字从此会出现在每次通过的输出里：
> 它无法再被忘记，也无法在无人察觉的情况下变大。

附录 A　证据等级说明

级别	含义	本文中的数量
untested	只是计划，没有执行	0
diagnostic	执行了，但用于诊断而非定论	部分
measured	有可追溯的测量记录	全部数值
reproduced	在独立环境被第二次测到	0
released	随产品发布并接受外部核验	0

附录 B　可复现性

本文全部图表由 scripts/render_paper.py 从 paper/data/*.csv 生成。每个数据行都有一列 cite，指向 research/rtx-pro-6000/claims.csv 里一个已存在的主张；渲染器在生成前会校验这些引用，缺一条就拒绝出图。

```
python scripts/render_paper.py research/rtx-pro-6000/paper --check
python scripts/render_paper.py research/rtx-pro-6000/paper
python scripts/audit_paper.py research/rtx-pro-6000/paper
```

本文不新增任何事实。凡需要推导的数字，推导过程已作为 derivation 字段写在对应主张上。

附录 C　本文与档案报告的关系

本目录下有两份长文档，相差 51 倍：

	PAPER.md / PAPER.pdf	REPORT.md
规模	33,539 字符	1,694,296 字符
结构	10 章、25 节、13 图、8 表	689 个顶层节（编号 1 到 692）
性质	综述：已收敛的判断	工作档案：逐轮的发现与失败记录
读者	想知道结论的人	想核对过程、或接手这项工作的人
是否自足	是，可独立阅读	否，需配合 claims.csv 使用

> *** 一句话分工
>
> REPORT.md 记录「我怎么知道的」，PAPER.md 给出「我知道什么」。
>
> 前者按时间组织（第 N 轮查了什么），后者按论证组织
> （这个问题该用什么证据回答）。

注意 档案的顶层节编号是 1 到 692 而有 689 个节，缺 15、258、261 三个号。
那三节在早期版本里被合并了，编号没有回收。这个缺口故意留着：
它让「某条结论是第几轮加的」可以被精确定位，回收编号会让旧的引用全部失效。

C.1 为什么不合成一份

两份文档的组织轴不同，合并必然牺牲其中一轴：

- 按时间组织，读者要读完 689 节才知道结论是什么；
- 按论证组织，读者看不到「这条结论是怎么被推翻又重建的」。

而后者恰恰是这份工作最该保留的部分——本文有 9 条主张标为 disputed，
它们的价值不亚于成立的结论，因为下一个人会遇到同样的分歧。

C.2 两份文档如何保持同步

单向同步：档案是唯一的真相源，论文只能引用它。

具体机制：

- 论文里每个数字后面挂一个方括号标记（形如 c- 加主张名），指向 claims.csv 的一个主张；
- audit_paper.py 检查每个这样的标记都存在，且论文里的数值能在该主张的证据里找到；
- 图表的数据文件每行有 cite 列，render_paper.py 出图前校验；
- 论文若引入档案里没有的数字，第 2 步直接失败。

故论文不可能包含档案里没有的事实。 这条约束是机器强制的，不靠作者自觉。

C.3 读者该怎么用

- 只想知道买不买：读 §3.4（预填解码之别）与 §9（成本悖论）两节，约 8 页。
- 要选型：读 §1（SKU 与容量两个前置问题）到 §6，约 18 页。
- 要核对某个数字：在该数字后找那个方括号标记，到 claims.csv 查该行，

再按 evidence_ids 到 evidence.csv 取原文引用。三级可追。

- 要接手这项工作：读 REPORT.md 最后 30 节（§10.666 之后），

那里是最近三轮的完整思路；再读 scripts/README.md 了解四道校验。

C.4 已知的不一致，以及为什么留着

本文正文与档案之间存在两处口径差异，都已在正文里标注：

- 成本效率 1047% 对 850%（§9.3）：来源原话与按两数相除的结果差 20%

而来源未展开口径；

- SKU 未指明 244 条（§1.1.4）：档案里 2,238 条主张中有 244 条无法定位 SKU，

本文引用的 46 条里有 17 条同样无法定位。

** 判据

这两处都不是等待修正的错误，而是等待更多来源的空白。
把它们抹平（比如取中间值、或按最可能的 SKU 归类）会让论文更整洁，
也会让它更不可信。